GCI WORLD 2026 SEPTEMBER | UNIVERSITY OF TOKYO

FINAL ASSIGNMENT

الدليل الشامل للـ Final Assignment

ما هو، وكيف يُقيَّم، وما الذي تقوله بياناتك فعلاً، وخطة العمل، وتقسيم الشغل مع Claude

الجزء الأول: ما هو الـ Final Assignment، هل يُضاف للسيرة الذاتية، التسليم والمواعيد والتقييم

الجزء الثاني: بياناتك الفعلية كما كشفها التحليل: الهيكل والجودة والعتبات ونتائج النماذج

الجزء الثالث: الخطوات التفصيلية من السوق حتى الأثر المالي، مع أسئلة توجِّهك بدل أن تعطيك الحل

الجزء الرابع: خطة العمل الزمنية من 10 إلى 28 نوفمبر ومعايير الإنجاز لكل مرحلة

الجزء الخامس: ماذا تفعل بنفسك وبماذا تستعين بـ Claude، مع أمثلة طلبات وأخطاء يجب تجنبها

الجزء السادس: قاموس المصطلحات، أسئلة مراجعة، قائمة فحص قبل التسليم، حدود المعلومات والمصادر

تاريخ إعداد الملف: 10 نوفمبر 2026

النسخة الثانية. مبنية على الملفات الرسمية وعلى تحليلي لـ Client.csv وRecord.csv. الأرقام قابلة لإعادة الحساب، ولا شيء هنا بديل عن عملك أنت. راجع «حدود المعلومات» في الجزء السادس.

فهرس المحتويات

الجزء الأول: ما هو الـ Final Assignment؟	**3**
الفكرة في دقيقة واحدة	3
هل هو مشروع أقدر أضيفه إلى سيرتي الذاتية؟	3
ما الذي يجب أن تسلّمه؟	4
المواعيد	5
كيف يُقيَّم؟	5
قواعد الاستشهاد والذكاء الاصطناعي	6
أخطاء قد تُفشل التسليم	7
الجزء الثاني: بياناتك الفعلية كما كشفها التحليل	**8**
1. الهيكل العام	8
2. أين كل عمود؟ وخريطة الأعمدة	8
3. تدقيق جودة البيانات	9
4. أين يتعارض التوثيق مع البيانات؟	11
5. ماذا تقول البيانات عن المغادرة؟	12
6. كم يحقق نموذج الـ tutorial على بياناتك؟	16
7. ما الذي لا تستطيع هذه البيانات إخبارك به؟	18
8. أسئلة تبني بها مقترحك (لا إجابات)	19
الجزء الثالث: الخطوات التفصيلية	**20**
الجزء الرابع: خطة العمل الزمنية	**31**
الجزء الخامس: ماذا تفعل بنفسك وبماذا تستعين بـ Claude	**34**
الجزء السادس: القاموس والمراجعة وحدود المعلومات	**38**

الجزء الأول: ما هو الـ Final Assignment؟

هذا الجزء مبني بالكامل على الملفات الرسمية التي أرسلتها: ملف README الخاص بالـ Final Assignment، وشرائح Final Assignment Tutorial، وملف Dataset Overview، ودفتر tutorial.ipynb. ما نقلته حرفياً من هذه الملفات أو ترجمته بشكل مباشر وضعته في صندوق رمادي، وما عداه شرح مني. وفي آخر الملف قسم «حدود المعلومات» يوضح ما لم أستطع التأكد منه.

الفكرة في دقيقة واحدة

السيناريو الرسمي: أنت Associate جديد في شركة استشارات IT. فريق المبيعات حصل على مشروع إثبات مفهوم (PoC) من شركة لديها بيانات ضخمة وخبرة محدودة في استثمارها. مهمتك: تحليل البيانات (EDA)، وبناء نموذج تعلم آلة واحد على الأقل، وتحديد المشكلة الجوهرية للعميل من الأدلة وتحليل السوق، ثم كتابة مقترح أعمال مبني على البيانات مع أثر مُقدَّر بالأرقام (زيادة إيرادات، توفير تكاليف، أو تقليل مخاطر).

بكلمات بسيطة: الشركة تقول لك «عندنا بيانات كثيرة، ساعدنا نستفيد منها». أنت لا تُسلِّمها نموذجاً فقط، بل تُسلِّمها **قراراً**: ما المشكلة، ولماذا نعتقد أنها المشكلة (دليل من البيانات والسوق)، وماذا نفعل، ولمن، وكم نتوقع أن نربح أو نوفر.

المصطلح	معناه هنا
PoC (Proof of Concept)	تجربة أولية قبل التنفيذ الكامل للتأكد أن الفكرة ممكنة ومفيدة. إذا نجحت قد تتحول إلى مشروع كامل.
Associate	موظف استشارات مبتدئ. المطلوب منك أن تتصرف كمستشار: تحلل، تقنع، وتتوقع الأثر.
العميل (Company A)	شركة اتصالات لاسلكية مجهولة الاسم. لديها بيانات نحو 100 ألف عميل ولا يوجد عندها فريق تعلم آلة.
المخرجات	شرائح PDF (حتى 15 شريحة)، ودفتر Jupyter قابل لإعادة التشغيل، وقائمة مراجع.
الحكم	على جودة المقترح وتماسكه، وليس على أعلى دقة للنموذج.

أهم جملة في الملفات كلها: الموديل أداة تدعم توصيتك، وليس هو التوصية. العبارة المتكررة في الـ tutorial أن النموذج الممتاز بدون توصية قابلة للتنفيذ لا يُعتبر تسليماً ناجحاً، وأن قولك «بنيت موديلاً بدقة عالية» وحده هو تقرير تقني وليس مقترح أعمال.

هل هو مشروع أقدر أضيفه إلى سيرتي الذاتية؟

نعم، يصلح أن يكون مشروعاً في قسم Projects، لأنه يجمع عناصر يبحث عنها أصحاب العمل: تحليل بيانات حقيقية الشكل (100 ألف صف تقريباً و100 عمود)، وبناء نموذج تعلم آلة، وربط النتائج بقرار عمل، وعرضه على جمهور غير تقني. وهو مرتبط ببرنامج من مختبر Matsuo-Iwasawa في جامعة طوكيو، وهذا يعطيه وزناً إضافياً.

لكن الأهم هو **كيف تكتبه**. الكتابة الصادقة والمحددة أقوى من العبارات الكبيرة.

قالب سطور السيرة الذاتية (املأ الأقواس بنتائجك الحقيقية فقط)

الأسطر التالية بالإنجليزية لأن أغلب السير الذاتية تُكتب بها. عدّل اللغة والصياغة بحسب سيرتك، وكل مقطع بين قوسين مربعين يجب أن تستبدله بشيء حقيقي من عملك.

> Project: [project title], Data-Driven Business Proposal | GCI World 2026, Matsuo-Iwasawa Lab, University of Tokyo
>
> Analyzed a telecom dataset of about 100K customers (EDA, feature engineering) and built [model name] reaching [metric = score] on a held-out test set.
>
> Proposed [intervention] for [target segment]; estimated [impact] under stated assumptions.
>
> Tools: Python, pandas, scikit-learn, [XGBoost or other], Google Colab.

هذا قالب شكلي فقط، وكل رقم فيه يجب أن يخرج من عملك أنت.

قواعد الصدق في السيرة الذاتية:

- اكتب أنه **مشروع دراسي (course project)** وليس عملاً لعميل حقيقي. لا تكتب أنه نُفِّذ أو طُبِّق فعلياً.
- اكتب الأثر المالي على أنه **تقدير مبني على افتراضات** (estimated)، لأنه كذلك فعلاً.
- لا تضع رقماً لم تحسبه بنفسك. إذا سألك المحاور عنه ولم تستطع شرحه فسيضر ذلك أكثر مما ينفع.
- لا تذكر «Honors» أو «Outstanding» إلا إذا أُعلنت رسمياً لك بعد التقييم.
- **رابط GitHub:** لم أجد في الملفات أي نص عن حقوق نشر البيانات أو الشرائح. لذلك لا ترفع ملفي Client.csv و Record.csv علناً، واسأل المنظمين في Slack قبل نشر النوتبوك أو الشرائح علناً.

كيف تحكيه في مقابلة (دقيقتان): المشكلة، ثم البيانات، ثم أهم اكتشاف، ثم الموديل ونتيجته، ثم التوصية، ثم الأثر المقدَّر مع افتراضاته، وأخيراً حدود عملك وماذا كنت ستفعل لو توفر وقت أكثر. حضِّر هذه القصة بعد التسليم مباشرة وأنت تتذكر التفاصيل.

ما الذي يجب أن تسلّمه؟

الملف	التفاصيل
1. الشرائح (PDF)	حتى **15 شريحة** تشمل صفحة العنوان والفهرس وفواصل الأقسام والمراجع. الزائد عن 15 قد يُهمَل. الحجم **10MB أو أقل**. تُصدَّر من PowerPoint أو Keynote أو Google Slides أو Figma.
2. قائمة المراجع	تُكتب في حقل References في Omnicampus: رابط أو مرجع في كل سطر، ويجب أن تطابق ما استشهدت به داخل الشرائح. **إذا استعملت أي ذكاء اصطناعي توليدي فألصق رابط المحادثة هنا.**
3. الدفتر (Notebook)	ملف .ipynb أو .py (أو ZIP إذا تعددت الملفات)، يحتوي تحليلاً **قابلاً لإعادة الإنتاج**.
تسمية الملفات	اسم حسابك في Omnicampus: الشرائح باسم الحساب مع .pdf، والدفتر باسم الحساب مع .ipynb (أو .py أو .zip).

الملف	التفاصيل
إعادة التسليم	مسموحة قبل الموعد. يُقيَّم **آخر تسليم فقط**، ويجب إرفاق كل الملفات من جديد في كل مرة.
التسليم المتأخر	**غير مقبول.** ولا يُقبل أي تعديل متأخر على المراجع أو الدفتر بعد الموعد.

رابط التسليم حسب الـ README: صفحة المقرر في Omnicampus (course 170). تأكد من الرابط الحالي من حسابك لأن بعض صور الشرائح من دفعة سابقة.

المواعيد

الحدث	بالتوقيت العالمي (UTC)	بتوقيت العراق (UTC+3)
فتح التسليم	8 أكتوبر، 12:00 صباحاً	8 أكتوبر، 3:00 صباحاً
آخر موعد للتسليم	**28 نوفمبر 2026، 11:30**	**28 نوفمبر، 2:30 ظهراً (السبت)**
موعدك الشخصي المقترح للتسليم	27 نوفمبر	الجمعة 27 نوفمبر

إحدى شرائح الـ Final Assignment Tutorial تعرض صورة من Omnicampus بتواريخ نيسان وحزيران (دفعة سابقة). تجاهلها. الموعد المعتمد عندي هو الوارد في شريحة «Submission Deadline» وفي الـ README، وكلاهما يقول 28 نوفمبر 11:30 UTC. ومع ذلك تأكد من الموعد داخل حسابك في Omnicampus.

كيف يُقيَّم؟

المتطلبات السبعة (من الـ README)

الـ README يقول إن التسليم يُقيَّم بحسب تحقق هذه المتطلبات، وإن عدم تحقق بعضها قد يؤدي إلى نتيجة غير ناجحة. الجدول التالي يشرح كل متطلب وكيف تثبته داخل الشرائح.

#	المتطلب	ماذا يعني عملياً	كيف تثبته
1	مقترح أعمال وليس تقريراً تقنياً	توصية واضحة تقول ماذا تفعل الشركة ولمن ولماذا	شريحة توصية بعنوان يقول القرار نفسه
2	مبني على EDA حقيقي لهذه البيانات	تحليل يبرز تحديات خاصة بالعميل وليس كلاماً عاماً	رسوم وأرقام من بيانات Company A
3	نموذج واحد على الأقل	اسم الموديل والمقياس والنتيجة، مع تفسير سبب الاختيار وكيف بُني وماذا تعلمت منه	اكتب الثلاثة **نصاً** على الشريحة. الصور وحدها لا تكفي
4	مصادر خارجية وتحليل سوق مع توثيق	أرقام واتجاهات من تقارير وأوراق، وكل ما استعرته يُوثَّق	تسمية المصدر على الشريحة وفي قائمة المراجع

#	المتطلب	ماذا يعني عملياً	كيف تثبته
5	مفهوم لمدير بلا خلفية ML	لغة بسيطة، ومع ذلك تشرح لماذا هذا الموديل وكيف عمل	رسم تخطيطي مبسط وعناوين تقول الفكرة
6	رسوم بيانية متعددة	ليس أرقاماً خاماً فقط	رسم لكل فكرة رئيسية
7	اتساق منطقي	المشكلة ثم التحليل ثم الموديل ثم التوصية ثم الأثر، خيط واحد	كل شريحة تجيب عن سؤال تركته السابقة

ملاحظتان من الـ README: (1) إذا كان الموديل **غير مناسب بوضوح** للبيانات فلا يُحتسب المتطلب. (2) المطلوب أن تشرح لماذا اخترت كل موديل وكيف بنيته وما الذي استفدته منه، حتى لو كان العرض الحقيقي في الشركات يتجاوز التفاصيل التقنية.

مستويات النجاح (من شريحة Recap في الـ tutorial)

المستوى	الحضور (من 14)	الواجبات (من 24 نقطة)	Final Assignment	Competition
Completed	7 أو أكثر	14 نقطة أو أكثر	Pass (**التسليم إلزامي**)	اختيارية
Honors	7 أو أكثر	14 نقطة أو أكثر	ضمن أعلى 10%	ضمن أعلى 20% (والشرطان معاً)
Outstanding	يُختار الطلاب حسب مجموع الدرجات الكلي			

- الواجبات الثمانية: كل واجب بحد أقصى 3 نقاط، و2 إذا تأخرت (فالمجموع 24).
- الشريحة تقول صراحة: **يجب تسليم الـ Final Assignment لإكمال الكورس.**
- الـ README يقول إن نتائج التقييم تُعلن عبر Slack بعد الموعد، وإن «Outstanding Students» يُختارون حسب الدرجات الكلية (Final Assignment وCompetition والحضور والواجبات)، وإن التفاصيل تُنشر في Slack.

لا يوجد في الملفات شرح لكيفية حساب «أعلى 10%» (أي معيار تصحيح، وكم عدد المصححين). لذلك لا أستطيع أن أخبرك بدرجة محددة تضمن الوصول إلى Honors. ما أستطيع قوله إن تحقيق المتطلبات السبعة بجودة عالية هو الطريق الوحيد المنطقي.

قواعد الاستشهاد والذكاء الاصطناعي

الاستشهاد

- **استشهد بكل بيانات أو طريقة أو رسم أو نص خارجي.** عدم الاستشهاد قد يُعتبر **انتحالاً** حتى لو لم تنسخ حرفياً، وأي طريقة أو رسم مستعار يحتاج مصدراً.

- يمكنك استعمال بيانات عامة إضافية، لكن اذكر مصدرها واشرح كيف أثرت في مقترحك.
- الاقتباس الحرفي ليس أساس الدرجة، بل تحليلك وتركيبك. القاعدة التقريبية: **أقل من 40%** من المادة النهائية اقتباساً مباشراً.
- ضع إشارة قصيرة أو حاشية على الشريحة نفسها، وضع كل المراجع في القائمة. القائمتان يجب أن تتطابقا.

الذكاء الاصطناعي

> من الـ FAQ الرسمي: يمكنك استعمال أي ذكاء اصطناعي توليدي لمناقشة المقترحات أو إنشاء مخططات وما شابه، لكن نسخ المخرجات لا يُعتبر عملك. وضع رابط المحادثة في قائمة المراجع إلزامي. ومن الـ FAQ أيضاً: يمكنك مناقشة العمل مع زملائك في جامعتك أو في Slack، لكن نسخ عمل أحد يُعتبر انتحالاً.

- **استبيان الذكاء الاصطناعي** في صفحة التسليم يوضح أن إجاباتك **لا تؤثر على الدرجة**، وهدفه فهم كيف يستعمل الطلاب هذه الأدوات. ومع ذلك فقواعد الاستشهاد والمراجع تبقى سارية.
- لا تضع في الاستبيان معلومات شخصية أو سرية، ولا تلصق نصوص المحادثات فيه.
- أجب بما حصل فعلاً. السؤال الرابع (Q4) يسأل كم من المحتوى المساعَد تستطيع شرحه بكلماتك، والهدف الذي تتجه إليه هو «كله».

> شرح كل حقل في الاستبيان موجود في الجزء الخامس.

أخطاء قد تُفشل التسليم

الخطأ	لماذا هو خطير
عدم التسليم أصلاً	بدون تسليم لا تكمل الكورس، ولا يوجد تسليم متأخر.
عرض يقول «بنيت موديلاً بدقة عالية» وينتهي	تقرير تقني وليس مقترح أعمال (المتطلب 1).
ذكر الموديل على شكل صورة فقط	المطلوب كتابة الاسم والمقياس والرقم نصاً (المتطلب 3).
أرقام سوق بدون مصدر	لا تقوي حجتك، وقد تُعد انتحالاً (المتطلب 4).
مراجع الشرائح لا تطابق قائمة Omnicampus	الـ README يطلب التطابق.
نسخ الأمثلة كما هي من الـ tutorial	الـ tutorial نفسه يقول إنه مرجع وليس قالباً، والأصالة تُكافأ.
تحليل لا يخدم التوصية	يكسر الاتساق المنطقي (المتطلب 7).
إرفاق ملف واحد عند إعادة التسليم	يجب إرفاق الشرائح والمراجع والدفتر كلها في كل مرة.
دفتر لا يعمل عند المصحح	المطلوب تحليل قابل لإعادة الإنتاج.

الجزء الثاني: بياناتك الفعلية كما كشفها التحليل

في النسخة الأولى من هذا الدليل لم أكن قد رأيت ملفي البيانات. الآن حلّلت Client.csv وRecord.csv بنفسي، وهذا الجزء يعرض ما وجدته: هيكل البيانات، وجودتها، ومواضع التعارض مع التوثيق، وما تقوله عن المغادرة، وكم يحقق نموذج الـ tutorial عليها. **كل رقم هنا قابل لإعادة الحساب في Colab**، وأنصحك أن تعيد حساب ما يهمك بنفسك قبل أن تبني عليه، لأن أرقامك أنت هي التي ستظهر في عرضك.

كيف حسبت (حتى تقارن): قراءة الملفين بـ pandas ودمجهما على Customer_ID، دون أي بيانات خارجية. النماذج: XGBoost (الإصدار 3.4.1) بـ random_state=42. التحقق المتقاطع: 5 طيات مع stratify. قد تختلف أرقامك قليلاً (جزء من الألف) باختلاف إصدار المكتبة.

1. الهيكل العام

البند	ما وجدته
Client.csv	100,000 صف و50 عموداً (49 ميزة + Customer_ID). 21 عموداً نصياً و28 رقمياً.
Record.csv	100,000 صف و51 عموداً: 49 ميزة، إضافة إلى Customer_ID, churn. كلها رقمية.
الدمج	**واحد لواحد تام**: المعرفات من 1000001 إلى 1100000، بلا تكرار وبلا معرف ناقص، وبالترتيب نفسه في الملفين. الدمج على Customer_ID يعطي 100,000 صف و100 عمود (98 ميزة + Customer_ID + churn).
الهدف churn	49,562 عميلاً غادروا (49.56%) مقابل 50,438 بقوا (50.44%).
months	من 6 إلى 61 شهراً، والوسيط 16. **لا يوجد عميل بأقل من 6 أشهر**، أي أن العينة مأخوذة من عملاء مضى على اشتراكهم نصف سنة على الأقل.

تصحيح لما كتبته في النسخة الأولى: العمود months موجود في **Record.csv** وليس في Client.csv. الدرس العملي: لا تخمّن موقع العمود، بل اطبع الأعمدة بعد الدمج.

2. أين كل عمود؟ وخريطة الأعمدة

المجموعة	الملف	الأعمدة (والمعنى حسب Dataset Overview)
الاشتراك والحساب	Client	uniqsubs, actvsubs (مشتركون في المنزل), new_cell (مستخدم جديد), crclscod (فئة الائتمان), asl_flag (حد إنفاق الحساب).
الجهاز	Client	eqpdays (عمر الجهاز بالأيام), hnd_price (سعره), phones, models (عدد الأجهزة والطرازات المصروفة), refurb_new (مُجدَّد أم جديد), hnd_webcap (قدرة الإنترنت), dualband.

المجموعة	الملف	الأعمدة (والمعنى حسب Dataset Overview)
تاريخ العميل (مدى الحياة)	Client	avgrev, totcalls, totmou, totrev, adjrev, adjmou, adjqty، ومتوسطات avgmou, avgqty، وآخر 3 أشهر avg3*، وآخر 6 أشهر avg6*.
المدة	**Record**	months: إجمالي أشهر الخدمة.
الإيراد والاستهلاك الشهري	Record	rev_Mean, mou_Mean, totmrc_Mean, da_Mean, ovrmou_Mean, ovrrev_Mean، و vceovr_Mean, datovr_Mean, roam_Mean, change_mou, change_rev.
جودة المكالمات	Record	drop_vce/dat, blck_vce/dat, unan_vce/dat (مقطوعة ومحجوبة وبلا رد), plcd, recv, comp (مُجراة ومستلمة ومكتملة), attempt_Mean, complete_Mean, drop_blk_Mean.
خدمة العملاء وأنماط الاستعمال	Record	custcare_Mean, ccrndmou_Mean, cc_mou_Mean (مكالمات خدمة العملاء), callwait, callfwdv, threeway, inonemin، وأعمدة الذروة وخارجها opk, *_peak_*، وwylis (من شبكة لاسلكية إلى لاسلكية).
الديموغرافيا	Client	prizm_social_one, area, truck, rv, ownrent, lor, dwlltype, marital, adults, infobase, income, numbcars, HHstatin, dwllsize, forgntvl, ethnic, kid0_2 ... kid16_17, creditcd.
الهدف والمفتاح	Record	churn (مغادرة بين 31 و60 يوماً بعد تاريخ الملاحظة), Customer_ID.

3. تدقيق جودة البيانات

القيم المفقودة

الأعمدة	نسبة المفقود	ملاحظة
numbcars	49.4%	عدد السيارات. القيم الموجودة من 1 إلى 3 فقط، فلا نعرف هل المفقود يعني صفراً أم مجهولاً.
dwllsize, HHstatin, ownrent, dwlltype	38.3%، 37.9%، 33.7%، 31.9%	أعمدة المسكن والأسرة.
lor, income, adults, infobase	30.2%، 25.4%، 23.0%، 22.1%	الإقامة والدخل والبالغون ومطابقة InfoBase.
hnd_webcap, prizm_social_one	10.2%، 7.4%	قدرة الجهاز، والمجموعة الاجتماعية.
avg6mou, avg6qty, avg6rev	2.84%	متوسطات آخر 6 أشهر.
truck, rv, marital, forgntvl, ethnic, creditcd, kid0_2 ... kid16_17	1.73% (1,732 عميلاً)	**نفس الصفوف** في كل هذه الأعمدة (تطابق تام). غالباً مجموعة لم تُطابَق في مصدر الديموغرافيا. نسبة مغادرتها 47.9%.

الأعمدة	نسبة المفقود	ملاحظة
hnd_price	0.85%	
change_mou, change_rev	0.89% (891 عميلاً)	**مغادرتهم 76.1%.**
rev_Mean, mou_Mean, totmrc_Mean, da_Mean, ovrmou_Mean, ovrrev_Mean, vceovr_Mean, datovr_Mean, roam_Mean	0.36% (357 عميلاً)	مغادرة من ليس لهم mou_Mean: 68.6%.

باقي أعمدة Record وباقي أعمدة الجهاز لا ينقصها شيء. وخلاصة مهمة: **الفراغ نفسه قد يحمل معلومة** (مجموعة 891 عميلاً بلا change_mou مغادرتهم 76%)، فلا تحذف الأعمدة أو الصفوف قبل أن تنظر إليه.

أعمدة شبه مكررة (ارتباط سبيرمان فوق 0.97)

وجدت 20 زوجاً. هذه أبرزها، وقد تحتاج أحد العمودين فقط في كل زوج:

الزوج	الارتباط	ماذا تتوقع
totcalls و adjqty	0.999	نسخة معدّلة من الفواتير
totmou و adjmou	0.999	نسخة معدّلة
totrev و adjrev	0.996	نسخة معدّلة
attempt_Mean و plcd_vce_Mean	0.999	شبه متطابقان
complete_Mean و comp_vce_Mean	0.999	شبه متطابقان
mou_cdat_Mean و comp_dat_Mean	0.999	عدد ودقائق نفس الشيء
mou_pead_Mean و peak_dat_Mean	0.999	عدد ودقائق
mou_opkd_Mean و opk_dat_Mean	0.999	عدد ودقائق
ovrrev_Mean و ovrmou_Mean	0.998	دقائق الزيادة وإيرادها
cc_mou_Mean و ccrndmou_Mean	0.998	دقائق مقرّبة وغير مقرّبة
mou_Mean و avg3mou	0.983	استعمال الشهر ومتوسط 3 أشهر

حذف أحد العمودين في الأزواج العشرة الأولى (10 أعمدة) لم يغيّر أداء النموذج عندي (AUC من 0.6960 إلى 0.6956). فائدته التبسيط وسهولة الشرح، وليس رفع الدقة.

أعمدة شبه فارغة (معظم قيمها صفر)

العمود	نسبة الأصفار	ملاحظة
callfwdv_Mean	99.57%	شبه معدوم
recv_sms_Mean	99.13%	872 عميلاً فقط غير صفري
blck_dat_Mean	98.77%	
drop_dat_Mean	97.40%	
unan_dat_Mean	96.88%	
forgntvl, peak_dat_Mean, mou_pead_Mean, opk_dat_Mean, rv	90% إلى 93%	أعمدة البيانات والسفر والمركبات الترفيهية
datovr_Mean, comp_dat_Mean, plcd_dat_Mean	85% إلى 87%	مكالمات البيانات قليلة جداً

قيم متطرفة وغريبة

العمود	ما رأيته
totcalls, totmou	وسيط totcalls 1,822 والأقصى 98,874. وسيط totmou 5,191 والأقصى 233,419.
uniqsubs	الوسيط 1، والنسبة 99% أقل من 6، لكن الأقصى **196** (13 عميلاً فوق 10).
rev_Mean	وسيط 48.2، والنسبة 99% أقل من 227.9، والأقصى 3,843. وفيه 5 قيم سالبة.
mou_Mean	وسيط 355، والنسبة 99% أقل من 2,422، والأقصى 12,207.
change_mou, change_rev	change_mou من −3,875 إلى 31,219. change_rev من −1,108 إلى 9,964.
eqpdays	من −5 إلى 1,823. وفيه **133 قيمة سالبة** (مغادرتهم 35%).
totmrc_Mean, avg6rev	totmrc_Mean فيه 23 قيمة سالبة (أدناها −26.9). avg6rev أدنى قيمة فيه −2.
hnd_price	17 قيمة مختلفة فقط (من 9.99 إلى 499.99)، أي أنه فئات أسعار وليس قيماً مستمرة.

4. أين يتعارض التوثيق مع البيانات؟

هذه الفروق مهمة لأنك ستصف الأعمدة في عرضك، والوصف الخاطئ يُضعف مصداقية التحليل.

العمود	ما يقوله Dataset Overview	ما تقوله البيانات
change_mou	نسبة التغير في الدقائق مقابل متوسط 3 أشهر سابقة	**22.6% من قيمه أقل من −100**، وهذا مستحيل لنسبة مئوية. ويرتبط بـ (mou_Mean − avg3mou) بمعامل 0.90. يبدو **فرقاً مطلقاً** وليس نسبة.
change_rev	نسبة التغير في الإيراد	نفس الملاحظة: ارتباطه 0.94 مع (rev_Mean − avg3rev). (استنتاج مني من الأنماط، وليس تأكيداً من الشركة.)
recv_sms_Mean	NaN (بلا وصف)	872 عميلاً فقط قيمتهم غير صفرية. عملياً **بلا فائدة**.
iwylis_vce_Mean	NaN (بلا وصف)	يتصرف كعدد مكالمات صوتية واردة من شبكة لاسلكية إلى لاسلكية: ارتباطه 0.785 مع mouiwylisv_Mean (دقائقها)، و0.73 مع نظيره الصادر owylis_vce_Mean. (استنتاج من الاسم والأنماط.)
Customer_ID	NaN (بلا وصف)	مفتاح الربط. صحيح وفريد.
عنوان الملف	GCI World 2026 Winter	بقايا من دفعة سابقة، ولا يؤثر على عملك.
ملف Client_1.csv	—	مطابق بايتاً بايت لـ Client.csv (نفس البصمة). استعمل أيّاً منهما.

إذا استعملت change_mou في عرضك فاكتب أنه «تغير في الدقائق» ولا تقل «نسبة مئوية»، أو وثّق ما تفترضه صراحة. هذه من الأمور التي يلتقطها قارئ دقيق.

5. ماذا تقول البيانات عن المغادرة؟

الإشارة ضعيفة بشكل عام

أقوى ميزة منفردة هي eqpdays، وقدرتها على الترتيب (AUC) 0.574 فقط، علماً أن 0.5 يعني لا شيء و1.0 يعني كمال. القيمة الأقل من 0.5 تعني أن ارتفاع الميزة يرافق **انخفاض** المغادرة (يمكنك قلب القراءة).

الميزة	AUC منفردة	الاتجاه
eqpdays	0.574	جهاز أقدم، مغادرة أكثر
hnd_price	0.442 (أي 0.558 مقلوبة)	جهاز أغلى، مغادرة أقل
totmrc_Mean	0.458	رسوم شهرية أعلى، مغادرة أقل
mou_Mean	0.461	استعمال أعلى، مغادرة أقل

الميزة	AUC منفردة	الاتجاه
iwylis_vce_Mean	0.464	مكالمات واردة أكثر، مغادرة أقل
custcare_Mean	0.471	مكالمات خدمة عملاء أكثر، مغادرة **أقل** (عكس التوقع)
change_mou	0.470	تراجع الاستعمال، مغادرة أكثر
months	0.525	تأثيره غير خطي (انظر أدناه)

لا يوجد عمود يفصل الفئتين بشكل مشبوه. أعلى AUC منفردة هي 0.574 فقط، فلا توجد علامة واضحة على تسرب الهدف (leakage) من أعمدة منفردة. هذا لا يغني عن أسئلة التسرب لميزات مشتقة تبنيها بنفسك.

اكتشاف 1: عتبة حادة عند نحو 300 يوم من عمر الجهاز

عمر الجهاز eqpdays	نسبة المغادرة	عدد العملاء	ملاحظة
100 فأقل	40.1%	10,663	
101 إلى 200	41.8%	11,856	
201 إلى 280	36.3% إلى 38.0%	14,267	ثلاث فئات متقاربة
281 إلى 290	37.7%	1,579	
291 إلى 300	**37.5%**	1,723	قبل العتبة
301 إلى 310	**54.7%**	2,293	**قفزة 17 نقطة**
311 إلى 320	60.0%	2,659	
321 إلى 340	64.5%	4,705	الذروة
341 إلى 450	54.1% إلى 58.6%	17,520	
451 إلى 800	53.3% إلى 54.4%	25,305	
أكثر من 800	59.3%	7,429	

الخطوة بين 300 و301 يوماً حادة جداً لدرجة أنها تستحق السؤال. قد تكون سلوكاً حقيقياً (مثلاً أهلية ترقية الجهاز أو نهاية فترة التزام قريبة من 300 يوم)، وقد تكون أثراً لطريقة تكوين العينة (والبيانات بنسبة مغادرة 49.6% غير طبيعية أصلاً). **لا أستطيع أن أحسم بين الاحتمالين من الملفات.** المهم أن تقولها بصدق في عرضك: «لاحظنا عتبة حادة، وفرضيتنا كذا، ولم نتأكد».

اكتشاف 2: عتبة عند 10 إلى 11 شهراً من مدة الاشتراك

الجدول التالي يوضح نسبة المغادرة بحسب مدة الاشتراك بالأشهر، من 6 إلى 61.

مدة الاشتراك months	نسبة المغادرة	عدد العملاء	ملاحظة
6	38.4%	1,295	
7	33.3%	4,979	
8	31.0%	3,728	
9	**28.8%**	4,066	أدنى نسبة
10	40.3%	4,313	
11	**65.1%**	8,029	**الأعلى**
12	61.9%	6,033	
13 إلى 14	54.4%	10,203	
15 إلى 18	51.5%	13,960	
19 إلى 24	50.6%	18,705	
25 إلى 36	50.0%	19,024	
37 فأكثر	47.3%	5,665	

العلاقة بين الاكتشافين: ثلاث مجموعات

هل العتبتان مستقلتان؟ لنقسم العملاء إلى ثلاث مجموعات حسب العمر والجهاز.

المجموعة	العدد	نسبة المغادرة
اشتراك 9 أشهر فأقل (وكلهم جهازهم 288 يوماً فأقل)	14,068	**31.8%**
اشتراك 10 أشهر فأكثر وجهاز 300 يوم فأقل	26,021	43.6%
جهاز أكثر من 300 يوم	59,911	**56.3%**

تنبيه تحليلي: لا يوجد عميل مدة اشتراكه 9 أشهر فأقل وعمر جهازه أكثر من 300 يوم (أقصى عمر جهاز بين المشتركين الجدد 288). فالمتغيران **متشابكان**: لا تنسب الأثر لأحدهما قبل أن تفصل بينهما (مثلاً بالمقارنة داخل مجموعة اشتراك 10 أشهر فأكثر فقط).

اكتشاف 3: العملاء الذين توقفوا عن الاستعمال

هنا المجموعات الأعلى مغادرة، وهي صغيرة نسبياً:

المجموعة	العدد	نسبة المغادرة
mou_Mean تساوي صفراً	1,615	**79.8%**
mou_Mean مفقودة	357	68.6%
mou_Mean أقل من أو تساوي 10 دقائق	3,848	65.4%
mou_Mean أقل من أو تساوي 30 دقيقة	7,187	60.8%
mou_Mean أقل من أو تساوي 65 دقيقة	12,507	57.8%
change_mou مفقودة	891	76.1%
المتوسط العام	100,000	49.6%

مجموعة صغيرة لكن عالية الدقة. اسأل: ما حجم الإيراد الذي تمثله؟ (متوسط rev_Mean لمن استعمالهم صفر هو 23.1 فقط مقابل 58.7 للجميع.) وهل هي مجموعة تستحق تدخلاً مستقلاً أم أنها «غادرت فعلاً»؟

مجموعات أخرى لافتة

مجموعات إضافية (النسبة المئوية هي نسبة المغادرة داخل المجموعة):

المجموعة	العدد	نسبة المغادرة	مقابل
hnd_price أقل من أو يساوي 29.99	26,094	57.5%	أعلى من 149.99: 41.0%
hnd_webcap = WC	13,843	56.3%	WCMB: 47.1%
refurb_new = R (مُجدَّد)	14,406	53.4%	N: 48.9%
asl_flag = Y	13,936	**40.9%**	N: 51.0%
uniqsubs أكبر من 2	10,478	53.8%	2 فأقل: 49.1%
custcare_Mean صفر أو شبه صفر	62,905	51.5%	4.3 فأكثر (11,885): 44.6%
crclscod = EA	6,419	41.0%	AA (36,509): 50.6%
area: DC/Maryland/Virginia	6,567	46.0%	California North: 52.1%

- **الإيراد لا يميز بين من غادر ومن بقي:** متوسط rev_Mean للباقين 59.2 وللمغادرين 58.2. لذلك فسؤال «من يستحق الاحتفاظ به أكثر» لا يُجاب بالإيراد وحده.
- **الاستعمال أقل عند المغادرين:** متوسط mou_Mean للباقين 543 وللمغادرين 483.
- **الديموغرافيا ضعيفة:** الدخل وعدد البالغين والحالة الاجتماعية تتراوح مغادرتها بين 48% و51%.

- **custcare:** من يتصلون أكثر بخدمة العملاء يغادرون **أقل**، وهذا عكس البداهة. ما التفسير المحتمل؟ (اجعله فرضية تختبرها، فلا تفترض أنه «المكالمات تحافظ على العميل».)

عمود ethnic: له قيمتان متطرفتان (Z: 39.7% مغادرة لـ 4,425 عميلاً، وO: 58.1% لـ 4,198). حتى لو ظهر أنه مفيد، فاستعمال العرق أساساً لاستهداف عروض قد يثير مشكلات عدالة وقانون تختلف باختلاف الدول. الأفضل أن تذكر هذا في المخاطر، وتبني توصيتك على سلوك العميل.

6. كم يحقق نموذج الـ tutorial على بياناتك؟

أشغّل نفس إعدادات الـ tutorial (ترميز LabelEncoder، وXGBoost بـ 300 شجرة، ومعدل تعلم 0.05، وعمق 6، وتقسيم 70/30 مع stratify وseed 42). هذه أرقام **للمعايرة**: إذا حصلت على شيء قريب منها فأنبوبك سليم.

المقياس (مجموعة الاختبار 30,000)	النتيجة	ملاحظة
خط الأساس (دائماً الفئة الأكبر)	50.4%	أدنى ما يجب تجاوزه
Accuracy	**63.6%**	
AUC	**0.694**	
Precision / Recall / F1	63.8% / 64.7% / 62.9%	
مصفوفة الالتباس	TN 9,454 | FP 5,677 | FN 5,251 | TP 9,618	الخطآن متقاربان تقريباً
Accuracy على التدريب	73.5%	**أعلى بـ 10 نقاط**
AUC على التدريب	0.815	فرق واضح عن 0.694: إفراط في التعلم

الرسالة الأهم: هذه بيانات **صعبة**. دقة 64% وAUC نحو 0.70 تعني أن الموديل أفضل من الصدفة، لكنه ليس قوياً. لذلك لا تبنِ مقترحك على جملة «موديلنا دقيق»، بل على **الترتيب والاستهداف** (من نختار أولاً)، وعلى حجم الأثر الاقتصادي الواقعي.

هل يتحسن النموذج؟ تجارب بالتحقق المتقاطع (5 طيات)

كل رقم هنا متوسط خمس طيات متقاطعة، والرقم بعد ± هو الانحراف المعياري بين الطيات.

التجربة	الميزات	AUC	Accuracy
E0: إعداد الـ tutorial (LabelEncoder)	98	0.6968 ± 0.0037	64.1%
E1: فئات أصلية بدل LabelEncoder	98	0.6960 ± 0.0026	64.0%

التجربة	الميزات	AUC	Accuracy
E1: E2 + حذف 10 أعمدة مكررة	88	± 0.6956 0.0030	64.0%
E2: E3 + 17 ميزة مشتقة (نسب وعلامات)	105	**± 0.7015 0.0025**	64.4%
E3: E4 + ضبط (عمق 4، 700 شجرة، معدل 0.03، عينات جزئية)	105	**± 0.7017 0.0023**	64.4%
E4: E5 + شجرة أضحل (عمق 3)	105	± 0.6980 0.0024	64.1%
E5: الضبط نفسه بدون الميزات المشتقة	88	± 0.6957 0.0027	64.1%
انحدار لوجستي بسيط (للمقارنة)	مُرمَّزة	0.6566	61.3%

- **الميزات المشتقة أعطت أكثر من الضبط:** نحو +0.005 AUC، بينما الضبط وحده لم يضف شيئاً (E6 مقابل E2). لكن هامش التقلب بين الطيات 0.002 إلى 0.004، فالفرق صغير، ولا تبنِ قصة كبيرة عليه.
- المشتقات التي جرّبتها: نسب بين الاستعمال الحالي والتاريخي، وعلامتا العتبتين (جهاز أكثر من 300 يوم، واشتراك 9 أشهر فأقل)، ونسب المكالمات الفاشلة وغير المجابة إلى المُجراة، وحصة الإيراد المتكرر، وغيرها. **لا أعطيك قائمة جاهزة**، فجرّب أفكارك أنت واسأل لماذا تتوقع أن تفيد كل واحدة.
- علامة «جهاز أكثر من 300 يوم» وحدها نالت 26.7% من «gain» في نموذج E4. أي أن العتبة التي وجدناها قوية فعلاً داخل النموذج.
- الانحدار اللوجستي البسيط ضعيف (0.657)، لأن العلاقات غير خطية (عتبات). سبب وجيه لاختيار نموذج شجري، ويصلح كمقارنة في عرضك.

جدول الاستهداف (أفضل نموذج E4، تنبؤات خارج العينة)

رتّبت العملاء حسب احتمال المغادرة، ونظرت إلى أعلى k% منهم:

أعلى k% بدرجة الخطر	الدقة (Precision)	الاستدعاء (Recall)	الـ Lift
أعلى 5%	85.5%	8.6%	1.73
أعلى 10%	**80.4%**	16.2%	1.62
أعلى 20%	74.3%	30.0%	1.50
أعلى 30%	70.0%	42.4%	1.41
أعلى 50%	64.0%	64.5%	1.29
أدنى 10% (الأقل خطراً)	مغادرتهم 18.3%	—	—

اقرأ الجدول هكذا: لو استهدفنا العشرة بالمئة الأعلى خطراً (10,000 عميل من 100,000)، فأربعة من كل خمسة سيغادرون فعلاً (مقابل نصف العملاء كمتوسط)، لكننا نلتقط 16% فقط من إجمالي المغادرين. **كلفة التدخل وقيمة العميل وحدهما تقرران أي نسبة تستهدف.**

أهم الميزات بحسب gain في نموذج الـ tutorial

حصة كل ميزة من إجمالي gain في نموذج الـ tutorial الأصلي:

الميزة	حصة gain	ملاحظة
eqpdays	4.6%	الأولى
months	3.6%	
refurb_new	3.1%	جهاز مُجدَّد أم جديد
mou_Mean	2.2%	
hnd_price	2.0%	
infobase	1.8%	ملفت: عمود مطابقة بيانات (تحقق من معناه)
uniqsubs	1.6%	
totmrc_Mean	1.6%	

- التوزيع **مسطح**: أعلى ميزة تأخذ 4.6% فقط. الإشارة موزعة على عشرات الميزات الضعيفة، وهذا يفسر ضعف الدقة.
- مثال على الفرق بين المقياسين: أكثر الميزات استعمالاً (weight) هي change_mou وchange_rev، بينما أعلاها فائدة (gain) هي eqpdays. لذلك نصح الـ tutorial بـ gain.

7. ما الذي لا تستطيع هذه البيانات إخبارك به؟

هذه حدود يجب أن تقولها بوضوح في عرضك، فهي جزء من صدقك العلمي.

ما ينقص	لماذا يهم
تاريخ الملاحظة والتسلسل الزمني	لا نعرف **متى** حدث شيء، فلا يمكن اختبار «الموديل يتنبأ بالمستقبل» زمنياً، ولا دراسة الموسمية.
نوع الخطة والعروض والأسعار	لا يوجد عمود للخطة ولا للعرض الحالي، فلا يمكن اقتراح «نقل العميل إلى خطة كذا» من البيانات وحدها.
تاريخ التدخلات السابقة	لا نعرف هل عُرض على أحد عرض احتفاظ ونجح. نسبة نجاح التدخل **لا توجد في البيانات**، وعليك أن تأخذها من مصدر أو تفترضها بوضوح.
الكلفة والعملة	لا توجد وحدة للإيراد (rev_Mean) ولا كلفة تدخل. اكتب «وحدة نقدية» أو وضّح افتراضك.

ما ينقص	لماذا يهم
السببية	الارتباط لا يثبت أن تغيير عمر الجهاز سيغيّر المغادرة.
واقعية نسبة 49.6%	نسبة المغادرة الواقعية في الاتصالات أقل بكثير (الـ tutorial يقول 5 إلى 10% في العالم الحقيقي). العينة تبدو معدّلة أو مأخوذة بطريقة تجعلها متوازنة، وسبب ذلك غير مذكور. أي تقدير مالي مبني على 49.6% مباشرة **سيبالغ**.

8. أسئلة تبني بها مقترحك (لا إجابات)

هذه الأسئلة تنبع مباشرة مما وجدته، وكلها تحتاج منك قراراً مدعوماً بتحليلك أنت:

- **العتبتان (300 يوم، 10 أشهر):** هل هما سلوك حقيقي أم أثر عينة؟ كيف تتحقق؟ وكيف يؤثر ذلك على توصيتك لو كانت حقيقية؟
- **التشابك بين عمر الجهاز ومدة الاشتراك:** كيف تفصل أثر كل منهما؟
- **المجموعات الصغيرة عالية الخطر (استعمال صفري):** هل تستحق مقترحاً مستقلاً؟ ما قيمتها وما التدخل المناسب لها؟
- **الهدف:** هل تبقى مع churn أم تصوغ سؤالاً آخر (قيمة معرضة للخسارة، أو شريحة معينة)؟ ماذا تكسب وماذا تخسر؟
- **الاستهداف:** أي نسبة (5% أو 10% أو 20%...) تعطي أفضل صافي بعد كلفة التدخل؟ كيف تعرض حساسية النتيجة؟
- **الإيراد غير مميز:** إذا كان المغادرون والباقون بنفس الإيراد، فما معنى «عميل ذو قيمة» في مقترحك؟
- **نسبة 49.6%:** كيف تعدّل تقديراتك لتبقى واقعية؟
- **الأخلاق والعدالة:** هل تستعمل عمود ethnic أو الدخل أو الحالة الاجتماعية؟ ولماذا؟ وماذا تقول عنه؟

الجزء الثالث: الخطوات التفصيلية

هذا الجزء يتبع المسار الذي يقترحه الـ README والـ tutorial (السوق، EDA، تعريف المشكلة، الميزات، التجارب، المقترح، الخطوات التالية)، وأضفت إليه خطوتين عمليتين في البداية والنهاية. لكل خطوة: الهدف، ما تفعله، أسئلة توجيهية، المخرج الذي يجب أن يكون بيدك في نهايتها، وفخاخ شائعة.

طريقة الاستعمال: أسئلة التوجيه ليست تمارين جانبية، بل هي الأسئلة التي سيحاسبك عليها المصحح ضمناً. لا أعطيك هنا إجاباتها عمداً، لأن إجاباتك أنت (من بياناتك) هي ما يصنع الأصالة، ولأن الـ README نفسه يقول إن نسخ مخرجات الذكاء الاصطناعي لا يُعتبر عملك.

> المسار ليس خطياً بالكامل. الـ workflow في شرائح الـ tutorial يضع سهماً يقول «كرر العملية»: قد يدفعك الـ EDA لتعديل الفرضية، وقد يدفعك الموديل للعودة إلى الميزات. هذا طبيعي ومطلوب.

الخطوة 0: التجهيز

الهدف

أن يعمل الدفتر على بياناتك من أول ساعة، قبل أن تفكر بأي تحليل.

ماذا تفعل

- حمّل مجلد Final Assignment من مواد الدورة، وفك الضغط، وارفعه إلى Google Drive (في أي مكان، لكن عدّل المسار لاحقاً).
- أنشئ دفتر Colab جديداً داخل المجلد نفسه، أو افتح tutorial.ipynb وانسخه باسم جديد وسمّه باسم حسابك في Omnicampus من الآن.
- شغّل أقسام الـ tutorial من 2 إلى 3 فقط (التحميل والدمج وأول EDA) وتأكد أن الشكل (shape) المطبوع معقول.
- إذا ظهرت رسالة ModuleNotFoundError لـ xgboost فشغّل pip install xgboost مرة واحدة ثم أعد تشغيل الجلسة (الـ tutorial يذكر هذا).
- **نقطة تحقق مهمة:** إذا شغّلت نموذج الـ tutorial كما هو (LabelEncoder، وXGBoost بـ 300 شجرة، ومعدل 0.05، وعمق 6، وتقسيم 70/30 مع stratify وseed 42) فيجب أن تحصل على Accuracy قرابة 63.6% و AUC قرابة 0.694 على الاختبار (راجع الجزء الثاني). إن حصلت على 80% أو أكثر فتحقق من وجود خطأ أو تسرب. وإن حصلت على 50% فربما كسرت الربط بين الملفين.

المخرج

دفتر يحمّل الملفين ويدمجهما ويطبع الأبعاد، وملف ملاحظات (مستند بسيط) تسجل فيه كل مصدر خارجي تقرأه من اليوم الأول، لأنك ستحتاجه للمراجع.

> **فخ:** لا تبدأ بتصميم الشرائح. ولا تنسخ كود الـ tutorial كله وتشغله دون قراءة. اقرأ كل سطر وتأكد أنك تعرف لماذا هو هناك.

الخطوة 1: فهم السوق (Market Analysis)

الهدف

أن تبرر لماذا هذه المشكلة مهمة في السوق، بأدلة قابلة للاستشهاد، وأن تبني قصتك على سوق تعرفه.

أسئلة توجيهية (من الـ README والـ tutorial)

- ما حالة سوق الاتصالات عالمياً ومحلياً؟ من اللاعبون الرئيسيون؟ ما الديناميكيات المحلية (التنظيم، التقنية، الداخلون الجدد) التي تؤثر في مغادرة العملاء؟
- ما الافتراضات المعقولة عن احتياجات العملاء؟
- كم نسبة المغادرة الطوعية (العميل قرر) مقابل غير الطوعية (عدم دفع أو تغيير عنوان)؟ وأيهما يستطيع الموديل التأثير فيه؟
- ما حجم السوق ونموه ومخاطره؟

أين تبحث

أمثلة على أنواع المصادر (تحقق بنفسك من توفرها وحداثتها وصلاحيتها للاستشهاد): تقارير الاتحاد الدولي للاتصالات (ITU)، وتقارير GSMA، وتقارير الهيئات المنظمة للاتصالات في بلدك (في العراق: هيئة الإعلام والاتصالات)، والتقارير السنوية لشركات الاتصالات (مثل زين العراق وآسياسيل وكورك)، وأوراق أكاديمية عن churn prediction في الاتصالات. لم أبحث هذه المصادر لك، وكل رقم تأخذه منها يجب أن تقرأه بنفسك وتوثقه.

المخرج

شريحة أو شريحتان: صورة السوق، مشكلة المغادرة أو غيرها بأرقام موثقة، وسبب ملاءمتها لحالة Company A. وفي ملف الملاحظات: قائمة المصادر مع تاريخ الدخول إليها.

> **فخ:** أرقام عالمية عامة بدون ربط بالعميل. الـ tutorial يقول إن مقترحاً مبنياً على سوق محلي تصفه بدقة أقوى من مقترح مجمّع من أرقام عالمية عامة. وأي رقم بلا مصدر **لا يقوّي حجتك**.

الخطوة 2: تحليل البيانات الاستكشافي (EDA)

الهدف

أن تفهم البيانات وتجمع أدلة تقود إلى فرضية، وليس أن تنتج أكبر عدد من الرسوم.

ماذا تفعل (بالترتيب)

- **الشكل والأنواع:** كم صفاً وعموداً؟ أي أعمدة نصية (object)؟ ستحتاج لتحويلها.
- **القيم المفقودة:** أي أعمدة ناقصة كثيراً؟ العمود الناقص أغلبه يحمل إشارة قليلة، وحذفه أنظف أحياناً من تعويضه.
- **الهدف:** كيف يتوزع؟ التوازن يحدد المقاييس الصالحة (الـ tutorial: الدقة مفيدة هنا لأن الفئات متوازنة، وتضلل لو كانت المغادرة 5%).

- **ميزة مقابل الهدف:** اختر ميزة واقارن توزيعها بين المغادرين والباقين، كما فعل الـ tutorial مع عمر الجهاز، لكن **على 3 أو 4 ميزات أخرى** من اختيارك.
- **نظرة على الشرائح:** هل تختلف نسبة المغادرة بحسب المنطقة أو فئة الائتمان أو نوع الخطة أو العمر الزمني للاشتراك؟

أسئلة توجيهية (من الـ tutorial)

- أي أعمدة قريبة من التكرار (عدة صيغ لنفس الإيراد أو الدقائق)؟
- هل يوجد عمود «أفضل مما يجب» قد يسرّب الهدف (leakage)؟
- أين القيم الشاذة أو غير المعقولة؟ وكيف تتعامل معها؟
- هل أي رسم يضلل (مقياس غير مناسب، تجميع في فئات يخفي شيئاً)؟

ثماني ملاحظات في بياناتك تحقق منها بنفسك

وجدتها في تحليلي (الجزء الثاني). لا تنقلها في عرضك قبل أن تعيد حسابها وتفهمها:

- **عتبة عمر الجهاز:** قارن نسبة المغادرة في شرائح ضيقة من eqpdays حول 300 يوم. هل ترى القفزة؟ هل هي حقيقية أم أثر تجميع؟
- **عتبة مدة الاشتراك:** قارن نسبة المغادرة لكل قيمة من months (6 إلى 14). أين تحدث القفزة؟
- **التشابك:** هل يوجد عملاء اشتراكهم قصير وجهازهم قديم؟ ما الذي يعنيه الجواب؟
- **استعمال صفري:** كم عميلاً لديه mou_Mean تساوي صفراً أو مفقودة، وكم نسبة مغادرتهم، وكم يمثلون من الإيراد؟
- **custcare:** كيف تتغير نسبة المغادرة مع عدد مكالمات خدمة العملاء؟ هل النتيجة معقولة؟ ما تفسيراتك؟
- **الإيراد:** هل يختلف rev_Mean بين المغادرين والباقين؟ وماذا يعني ذلك لتعريف «العميل القيّم»؟
- **الفراغ المنظم:** هل صفوف الديموغرافيا الناقصة (1.73%) هي نفسها في عدة أعمدة؟ وكم نسبة مغادرتها؟
- **معنى change_mou:** هل هي نسبة مئوية فعلاً؟ تحقق من نطاق قيمها قبل أن تصفها في عرضك.

أدوات مفيدة (أسماء دوال للبحث، وليست حلولاً جاهزة)

الدالة أو الفكرة	الاستعمال المحتمل
df.groupby('churn')[عمود].mean()	مقارنة متوسط ميزة بين المجموعتين.
pd.crosstab / value_counts(normalize=True)	نسب الفئات داخل كل شريحة.
pd.qcut / pd.cut	تقسيم ميزة رقمية إلى شرائح لرؤية معدل المغادرة في كل شريحة.
df.corr()	ارتباط بين الأعمدة الرقمية (لاكتشاف المتكرر).
np.log1p	تخفيف الانحراف في المتغيرات الموجبة المنحرفة، كما في pairplot الـ tutorial.
sample(n, random_state)	أخذ عينة للرسوم الثقيلة.

المخرج

من 4 إلى 6 رسوم تقود إلى **فرضيتين أو ثلاث** مكتوبة بجمل كاملة (مثل: «الفئة X أكثر عرضة لـ Y لأن Z»)، مع تحديد أيها أكثر قابلية للعمل عليها تجارياً.

> **فخ التسرب (Data leakage):** إذا ظهر عمود يفصل الفئتين بشكل شبه مثالي، فلا تفرح. اسأل: هل هذه المعلومة متاحة فعلاً **قبل** أن نحتاج التنبؤ؟ هل يمكن أن تكون مشتقة من الهدف أو من فترة بعده؟ الـ tutorial يطلب منك صراحة التفكير فيها.

الخطوة 3: تعريف المشكلة (أهم خطوة)

الهدف

أن تقرر ماذا تحل بالضبط. ما بعد هذه الخطوة كله يُبنى عليها.

> من الـ tutorial: اختيار السؤال هو أول مهمة للمحلل، وبقية المقترح يقوم أو يسقط عليه. والبيانات لا تشير إلى جواب واحد واضح، بل تقبل عدة أسئلة، وما تختاره يحدد نوع التوصية. يمكنك، بل يُستحسن، أن تستكشف أهدافاً أخرى غير churn: الإيراد، الاستخدام، دورة حياة الجهاز، سلوك شريحة معينة.

أسئلة لا بد أن تجيب عنها كتابة

- هل churn هو الهدف الأنسب **لمقترحي أنا**؟ ولماذا؟ (الـ FAQ: يمكنك اختيار أي هدف، لكن برر من EDA وسياق السوق.)
- ما نوع مهمة ML التي يعنيها هدفي: تصنيف، تراجع، تجميع (clustering)، كشف شذوذ؟ لكل نوع مقاييس وتوصيات مختلفة.
- كيف أقول سؤالي في **جملة واحدة** يفهمها مدير غير تقني؟
- **من يتصرف بنتيجة الموديل؟ وما التصرف؟** نموذج لا يمكن لأحد أن يتصرف بناءً عليه ليس مقترحاً.
- ما التوصية المتوقعة؟ (اكتب فكرة أولية الآن وعدلها لاحقاً.)

الاختيار	ما يعنيه	ما يجب أن تكون قادراً على قوله
هدف تصنيف (مثل churn)	نحدد من سيغادر	ما الفعل الذي نفعله لمن نتوقع مغادرته؟
هدف تراجع (مثل إيراد مستقبلي)	نتوقع رقماً	كيف يتغير القرار بحسب الرقم؟
تجميع شرائح	نقسم العملاء إلى مجموعات	ماذا نفعل بكل مجموعة؟
كشف شذوذ	نكتشف السلوك غير المعتاد	ما الحالة التي نعتبرها مشكلة؟

خيارات لتعريف المشكلة تدعمها بياناتك (لتفكر بها، لا لتنسخها)

هذه خمس زوايا ممكنة بحسب ما وجدته. اختر واحدة أو ابتكر غيرها، لكن **ابنِ اختيارك على أدلتك أنت**، واذكر ما يضعفه.

الزاوية	ما تدعمه بياناتك	ما قد يضعفها
توقع المغادرة واستهداف الأخطر (تصنيف)	الهدف موجود، ونموذج بسيط يعطي دقة 80% في أعلى 10%.	الإشارة ضعيفة عموماً (AUC نحو 0.70)، ونسبة المغادرة 49.6% غير واقعية.
دورة استبدال الجهاز	قفزة حادة في المغادرة بعد نحو 300 يوم من عمر الجهاز، وأثر سعر الجهاز.	لا نعرف سببها، وقد تكون أثر عينة. ولا يوجد عمود للعروض أو الالتزام.
الإنذار المبكر لانخفاض الاستعمال	مجموعة صغيرة بمغادرة 65% إلى 80%.	مجموعة صغيرة وإيرادها منخفض. وقد تكون «غادرت فعلاً».
قيمة معرضة للخسارة (احتمال × إيراد)	الإيراد لا يميز المغادرين، فيكون الترتيب بالقيمة مفيداً.	يحتاج افتراضاً عن مدة بقاء العميل وكلفة العرض.
تجزئة العملاء (clustering) بتدخلات مختلفة	مجموعات واضحة في عمر الجهاز ومدة الاشتراك والاستعمال.	التجزئة وحدها لا تقول «ماذا نفعل»، وتحتاج ربطاً بالنتائج.

المخرج

فقرة من 3 إلى 5 جمل تجيب عن: ما المشكلة، ولمن، وما الهدف (target) ونوع المهمة ولماذا، وما القرار المتوقع. اجعلها أساس شريحة «تعريف المشكلة».

> لو لم تستطع كتابة هذه الفقرة بوضوح فلا تنتقل للموديل. هذا ما يفرق بين «تحليل بيانات» و«مقترح أعمال».

الخطوة 4: التجهيز وهندسة الميزات

الهدف

تحويل البيانات الخام إلى مدخلات تستطيع النماذج استعمالها دون أن تُفسد الإشارة، وإضافة ميزات تلتقط ما لا يلتقطه عمود واحد.

قرارات يجب أن تتخذها

هذه القرارات تؤثر في جودة الموديل أكثر مما يؤثر فيها اختيار الخوارزمية. قيّم كل واحد منها بدل أن تتبع الإعداد الافتراضي.

القرار	الخيارات	ما يجب أن تقيّمه
القيم المفقودة	حذف العمود، تعويض بالمتوسط أو الوسيط أو قيمة خاصة، أو ترك NaN لموديل يتعامل معه	XGBoost يتعامل مع NaN داخلياً، بينما الانحدار اللوجستي يحتاج تعويضاً وتحجيماً.
الأعمدة النصية	LabelEncoder (كما في الـ tutorial)، أو ترميز آخر، أو موديل يدعم الفئات	هل يفرض الترميز ترتيباً مصطنعاً؟ وكيف تعامل NaN؟
الأعمدة المكررة	الإبقاء على الأكثر معنى أو الأقل ضجيجاً	كيف تتأكد بدون تخمين؟

القرار	الخيارات	ما يجب أن تقيّمه
القيم الشاذة	قص، تحويل لوغاريتمي، أو تركها	هل هي أخطاء أم سلوك حقيقي؟
الأعمدة المشبوهة بالتسرب	حذف أو اختبار بدونها	ماذا يحدث للدقة؟

حقائق عن بياناتك تؤثر في المعالجة

- **21 عموداً نصياً كلها في Client.csv.** بعضها فيه قيم مفقودة كثيرة (ownrent وdwlltype وHHstating و dwllsize وinfobase). فكّر هل «المفقود» فئة بحد ذاته.
- **الفراغ المتطابق:** 1,732 صفاً ينقصها نفس مجموعة أعمدة الأسرة. علامة بسيطة قد تلتقط هذا.
- **الأعمدة المتكررة:** 10 أعمدة نسخ شبه مطابقة لأعمدة أخرى (الجزء الثاني). حذفها لم يغيّر الأداء لكنه يبسّط الشرح.
- **الأعمدة شبه الفارغة:** مثل recv_sms_Mean وcallfwdv_Mean. لا تضيف شيئاً تقريباً.
- **العتبات:** النماذج الشجرية تلتقط العتبات تلقائياً، لكن النماذج الخطية لا تلتقطها (الانحدار اللوجستي البسيط حقق 0.657 AUC فقط). هذا يؤثر على اختيارك للنموذج وعلى تبريرك.
- **القيم السالبة غير المنطقية:** 133 عميلاً بـ eqpdays سالب. هل تعدّلها أم تتركها؟ ولماذا؟

هندسة الميزات (Feature Engineering)

الـ tutorial يعطيك فكرتين فقط كمثالين عامين: **عمر الجهاز نسبةً إلى مدة الاشتراك**، و**تغير الاستخدام نسبةً إلى السلوك المعتاد**. ما بعد ذلك عليك أنت. اسأل: ما النسب أو الفروق أو التجميعات التي تعبر عن سلوك أو حالة (تراجع، ضغط على الشبكة، قيمة العميل، اعتماد على خدمة العملاء) أكثر من عمود منفرد؟ ولماذا تتوقع أن تفيد؟ (الفرضية قبل التجربة.)

> اكتب لكل ميزة جديدة سطراً: الاسم، المعادلة، السبب المتوقع. هذه الأسطر ستصبح شريحة أو جزءاً من شريحة «الميزات»، وتدلل على فهمك.

> **فخ:** إنشاء عشرات الميزات بلا سبب. الجودة قبل الكمية. وانتبه ألا تستعمل أي معلومة غير متاحة وقت التنبؤ.

الخطوة 5: بناء الموديل

الهدف

الحصول على دليل كمي يدعم توصيتك، مع تبرير اختيارك.

أسس يشرحها الـ tutorial

- **لماذا تقسيم تدريب واختبار؟** لتقييم الموديل على بيانات لم يرها. (الـ tutorial يستعمل 70% تدريب و30% اختبار.)
- **لماذا stratify؟** يحافظ على نسبة الفئتين في كلا الجزأين.
- **لماذا random_state؟** لتكرار النتائج عند إعادة التشغيل.

- **لماذا XGBoost؟** لأن البيانات جدولية بمقاييس مختلطة، وهو لا يحتاج تحجيماً، ويتدرب بسرعة على نحو 100 ألف صف، ويعطي أهمية للميزات. لكنه **خيار من خيارات**: الانحدار اللوجستي للتفسير، وغابات عشوائية، و LightGBM كلها معقولة.

ما الذي يفرق مقترحك

- **مقارنة أكثر من موديل** (الـ README: مفضلة). موديل بسيط قابل للتفسير بجانب موديل أقوى يعطي قصة جيدة: كم نكسب من التعقيد؟
- **خط أساس (baseline):** ماذا لو توقعنا دائماً الفئة الأكبر؟ يجب أن يتفوق موديلك بوضوح على هذا.
- **فحص الإفراط في التعلم (overfitting):** قارن الأداء على التدريب والاختبار. فرق كبير إشارة تحذير.
- **التحقق المتقاطع (cross-validation)** يعطي صورة أكثر ثباتاً من تقسيم واحد.
- اضبط الإعدادات بشكل معقول، لكن لا تقضِ أسبوعاً في ضبطها. الـ tutorial نفسه يقول إن الهدف ليس أفضل دقة ممكنة.

ماذا تتوقع من النتائج؟ (أرقام للمعايرة)

- نموذج الـ tutorial: Accuracy نحو 63.6% وAUC نحو 0.694 على الاختبار. وعلى التدريب Accuracy 73.5%، أي **إفراط واضح في التعلم**.
- بالتحقق المتقاطع: حذف الأعمدة المكررة وتغيير الترميز لا يغيّران شيئاً تقريباً. الميزات المشتقة الجيدة رفعت AUC نحو 0.005. الضبط الإضافي لم يرفعه. أي أن **الميزات أهم من المعاملات** في هذه البيانات.
- لا تتوقع قفزات: لو حصلت على 75% أو أكثر فاشتبه بتسرب في ميزة مشتقة قبل أن تحتفل.
- سجّل **كل تجربة** (ماذا غيرت، والـ AUC والانحراف بين الطيات). فرق أقل من الانحراف المعياري (نحو 0.0025) قد يكون ضوضاء.

> **فخ:** موديل «غير مناسب بوضوح» لنوع البيانات أو الهدف لا يُحتسب (الـ README). فكّر في تطابق الموديل مع المهمة (مثلاً لا تستعمل تصنيفاً على هدف رقمي مستمر).

الخطوة 6: التقييم

المقاييس الأساسية

المقياس	ماذا يقيس	متى يكون أنسب
Accuracy	نسبة التوقعات الصحيحة من الكل	عندما تكون الفئات متوازنة ولا فرق كبير بين كلفة الخطأين.
Precision	من كل من توقعنا مغادرته، كم غادر فعلاً؟	عندما يكون «الإنذار الكاذب» مكلفاً (عرض مكلف لمن لن يغادر).
Recall	من كل من غادر فعلاً، كم التقطنا؟	عندما يكون «تفويت المغادر» أغلى.
F1	توازن بين Precision, Recall	عندما تريد رقماً واحداً يوازن بينهما.

المقياس	ماذا يقيس	متى يكون أنسب
AUC	قدرة الموديل على ترتيب المغادر فوق الباقي	عندما تهتم بالترتيب (من نستهدف أولاً) وليس بحد قطع واحد.

مصفوفة الالتباس (Confusion matrix)

أربع خانات: باقٍ صُنِّف باقياً، ومغادر صُنِّف مغادراً، ومغادر فاتنا، وباقٍ صُنِّف مغادراً خطأً. **لكل خانة نتيجة مالية مختلفة**، ولهذا هي الجسر بين الموديل والأعمال.

أسئلة توجيهية (من الـ tutorial)

- هل دقتك تتفوق بوضوح على خط الأساس؟ إن لم تتفوق فالموديل لا يضيف دليلاً بعد.
- هل الخطأن متساويان في الكلفة في حالتي؟ ما كلفة كل منهما بالأرقام؟
- ما المقياس الذي يتناسب أكثر مع هدف مقترحي؟
- هل الدقة العالية مشبوهة؟ فكّر بالتسرب.

المخرج

جدول مقارنة صغير (موديل، مقياس، رقم) وصورة مصفوفة الالتباس مع جملة تفسيرية، وكتابة **اسم الموديل والمقياس والنتيجة** نصاً على الشريحة (شرط README).

الخطوة 7: أهمية الميزات وتفسير النتائج

ما تقدمه الـ tutorial

XGBoost يعطي مقياسين بسيطين: weight (كم مرة استُعملت الميزة في الأشجار) وgain (كم حسّنت الموديل عند استعمالها). الـ tutorial يقول إن gain أنسب لسؤال «أي الإشارات مهمة»، لأن ميزة قد تُستعمل كثيراً وتساهم قليلاً أو العكس.

أسئلة توجيهية

- خذ أعلى 3 إلى 5 ميزات. لكل منها: هل تستطيع الشركة **تغييرها فعلاً**؟ مثال الـ tutorial: عمر الجهاز وعدد مكالمات خدمة العملاء قابلان للتدخل، بينما مدة الاشتراك والديموغرافيا ليست كذلك. **الأهمية مع إمكانية التدخل تصنع الرافعة (lever).**
- لماذا يُحتمل أن تؤثر كل ميزة؟ الأهمية تقول إن الموديل يستعملها، وليس لماذا. القصة التي يمكن أن يسأل عنها مدير مالي هي ما يُحاسب عليه مقترحك.
- اختبار صغير اقترحه الـ tutorial: احذف أعلى ميزة وأعد التدريب. هل تبقى القصة نفسها أم يتغير الترتيب؟ هذا يكشف إن كان عندك إشارة واحدة قوية أم عدة ميزات متشابهة تعبر عن سبب واحد.

> **فخ:** الخلط بين الارتباط والسببية. أهمية الميزة لا تثبت أن تغييرها سيغير النتيجة. اذكر هذه الحدود في شريحة المخاطر وفي صياغتك («مؤشر» وليس «سبب»).

الخطوة 8: من الموديل إلى المقترح والأثر المالي

الهدف

تحويل «احتمال لكل عميل» إلى «قرار عمل وأثر مقدَّر». هذه الخطوة تفصل بين التسليم الناجح والقوي، كما يقول الـ tutorial.

ما الذي يجب أن تجيب عنه

- **ماذا نفعل** بعميل عالي الخطر: عرض احتفاظ؟ اتصال خدمة؟ تغيير خطة؟ ترقية جهاز؟ هذا يحدد معنى «نجاح التدخل».
- **كم نستهدف؟** لو رتبنا العملاء بحسب درجة الموديل واستهدفنا أعلى 10% أو 20% أو غيرها، فكم نسبة المغادرين الفعليين الذين نلتقطهم، وما حد القطع الأمثل بالنظر إلى كلفة التدخل؟
- **ما الأرقام الاقتصادية؟** متوسط إيراد العميل (ARPU)، كلفة التدخل، احتمال نجاحه. بعضها من مصدر خارجي موثق، وبعضها **افتراض تعلنه بوضوح** وتختبر حساسيته.
- **ماذا لو أخطأ الموديل؟** وماذا لا يغطيه مقترحك؟

معادلة الأثر المتوقع (من الـ tutorial، بصياغة مفصّلة مني)

صافي الأثر = عدد المستهدفين × (نسبة المغادرين الفعليين بينهم) × نسبة نجاح التدخل × قيمة العميل المحتفظ به − عدد المستهدفين × كلفة التدخل الواحد.

مثال توضيحي بأرقام وهمية تماماً (لتفهم الشكل فقط، وليس لتستعملها): استهدفنا 10,000 عميل، ونسبة المغادرين الفعليين بينهم 60%، ونجاح التدخل 20%، وقيمة العميل المحتفظ به 300 وحدة نقدية، وكلفة التدخل 15 وحدة. الحساب: 10,000 × 0.6 = 6,000 مغادر. 6,000 × 0.2 = 1,200 عميل محتفظ به. 1,200 × 300 = 360,000. الكلفة = 10,000 × 15 = 150,000. **الصافي = 210,000.** لاحظ أن الكلفة تُدفع على كل المستهدفين، حتى من لن يغادروا.

المتغير	مصدره المحتمل	كيف تتعامل مع عدم اليقين
نسبة المغادرين بين المستهدفين	نتيجة موديلك على بيانات الاختبار	اذكر أنها من عينة وأن الواقع قد يختلف.
نسبة نجاح التدخل	دراسة أو تقرير موثق، أو افتراض معلن	اعرض سيناريوهات (متحفظ، متوسط، متفائل).
قيمة العميل	من بياناتك (إيراد شهري، مدة متوقعة) أو مصدر	وضّح طريقة الحساب.
كلفة التدخل	افتراض معلن أو مصدر	حلّل الحساسية: متى يصير الصافي صفراً؟

ملاحظة عن 50% churn: إذا كانت نسبة المغادرة في البيانات 50% ولكن الواقع 5 إلى 10%، فتطبيق النسب مباشرة على سوق حقيقي سيبالغ في الأثر. وضّح هذا الافتراض أو عدّل الحساب. (هذه نقطة تحليلية مني، وتدل على تفكير ناضج.)

أرقام من بياناتك تساعدك في الحساب (تحقق منها)

الرقم	القيمة	ملاحظة
متوسط الإيراد الشهري rev_Mean	58.7	الوسيط 48.2، والربيعان 33.3 و70.8. **الوحدة غير مذكورة** في الملفات.
إيراد من استعمالهم صفري	23.1	أقل بكثير من المتوسط.
حجم الاستهداف	10,000 عميل لكل 10%	لأن العينة 100,000 عميل.
دقة أعلى 10% بدرجة الخطر	نحو 80%	من نموذج E4 على عينة مغادرتها 49.6%، فتعدّل ذلك للواقع.
مغادرة أدنى 10%	نحو 18%	تبين أن الموديل يميز الطرفين فعلاً.

ما لا يوجد في بياناتك: نسبة نجاح التدخل، وكلفته، وعمر العميل المتبقي. هذه تأتي من مصدر موثق أو افتراض معلن واختبار حساسية.

المخرج

شريحة مقترح واضحة (ماذا ولمن ولماذا)، وشريحة أثر كمي بافتراضات مكتوبة وسيناريوهات، وشريحة مخاطر وخطوات تالية.

الخطوة 9: بناء الشرائح

هيكل مقترح (من مسار الـ README)

العدد ليس هو المهم. الـ FAQ يقول إن عدد الشرائح لا علاقة له بالدرجة، لكن يجب أن تتضمن كل ما يقنع العميل. هذا تقسيم من 15 شريحة كحد أقصى تتبدل فيه حسب مقترحك.

#	الشريحة	رسالتها
1	العنوان	عنوان يقول فكرة المقترح، واسمك.
2	الملخص التنفيذي	الجواب أولاً: المشكلة والتوصية والأثر المقدّر في ثلاثة أسطر.
3	السوق	لماذا المشكلة مهمة (بأرقام موثقة).
4	العميل والبيانات	ماذا لدينا وما حدوده.
5-6	أهم نتائج EDA	اكتشافان أو ثلاثة تقود إلى المشكلة.
7	تعريف المشكلة	الهدف ونوع المهمة والقرار.
8	الميزات	ماذا بنيت ولماذا.
9	التجارب	الموديلات والمقياس والرقم (نصاً).

#	الشريحة	رسالتها
10	ماذا تعلمنا	أهمية الميزات، ومصفوفة الالتباس، وتفسير للأعمال.
11	المقترح	ماذا نفعل ولمن.
12	الأثر المقدّر	الحساب والافتراضات والسيناريوهات.
13	المخاطر والخطوات التالية	حدود وخطة تنفيذ مقترحة.
14	المراجع	تطابق قائمة Omnicampus.
15	احتياط	ملحق أو شريحة فارغة تتركها لما قد تحتاجه.

قواعد تحسين الشرائح (من الـ README)

- الجمهور بلا خلفية ML، لكن حذف التفاصيل التقنية بالكامل غير مناسب في PoC. ترجم الطرق إلى لغة مفهومة واستعمل مخططات مفاهيمية.
- عناوين واضحة تقول الفكرة (جمل لا أسماء)، وأضف ملخصاً عند الحاجة.
- صمّم كل رسم بغرض: اختر الألوان والخطوط والوحدات والأسطورة بعناية، وعالج القيم الشاذة والتجميع حتى لا يضلل الرسم.
- رسوم كثيرة تشتت، وقليلة تخفي النتائج. وازن.

الخطوة 10: تنظيف الدفتر وإثبات إعادة الإنتاج

- رتب الدفتر بعناوين تطابق الشرائح (السوق، EDA، المشكلة، الميزات، الموديل، الأثر).
- ضع في أول الدفتر وصفاً قصيراً وبنية المجلد المطلوبة لتشغيله (أين توضع الملفات).
- ثبّت random_state في كل مكان عشوائي.
- قبل التسليم: **Restart session and Run all** وتأكد أن كل الخلايا تعمل بالترتيب بدون أخطاء.
- احذف الخلايا التجريبية الميتة، وتأكد أن الأرقام في الشرائح هي نفسها التي ينتجها الدفتر الآن.
- لا تضع مفاتيح API أو بيانات شخصية في الدفتر.

الخطوة 11: التسليم

- ارفع الملفات بالأسماء الصحيحة (اسم حسابك في Omnicampus).
- املأ حقل المراجع، وألصق رابط محادثة الذكاء الاصطناعي إن استعملت.
- أجب عن استبيان الذكاء الاصطناعي بصدق (راجع الجزء الخامس).
- اضغط الزر الأخضر Submit، ثم افتح الصفحة وتأكد من حالة التسليم وأن الملفات ظاهرة.
- سلّم مبكراً (يوم قبل الموعد على الأقل). يمكنك إعادة التسليم قبل الموعد، لكن لا شيء بعده.

الجزء الرابع: خطة العمل الزمنية

اليوم هو الثلاثاء 10 نوفمبر 2026، والموعد النهائي السبت 28 نوفمبر الساعة 2:30 ظهراً بتوقيت العراق. أي أنك تملك **18 يوماً**، منها 10 أيام فقط حتى مسابقة الدورة. الخطة التالية اقتراح مني وليست من الـ README، فعدّلها بحسب جدول جامعتك.

> **تقاطع مع مسابقة الدورة:** موعد المسابقة 20 نوفمبر (الجمعة) الساعة 1:00 UTC، أي 4:00 فجراً بتوقيت العراق (تأكد منه من صفحة المسابقة). لذلك جعلت أيام 15 إلى 19 للمسابقة بالدرجة الأولى، وخصصت لـ Final Assignment في هذه الأيام ساعة واحدة يومياً للبحث والقراءة فقط. ما تتعلمه في المسابقة (التحقق، الميزات، مقارنة النماذج) يفيدك هنا، لكن **لا تنسخ حل المسابقة**، فالبيانات والمشكلة مختلفتان.

الجدول الزمني المقترح

التاريخ	المرحلة	المهام	المخرج المطلوب
10 إلى 11 نوفمبر	0. التجهيز والمعايرة	رفع الملفين إلى Colab، تشغيل أقسام الـ tutorial من 2 إلى 6، وتحقق أن نتائجك قريبة من أرقام الجزء الثاني (Accuracy قرابة 63.6%، AUC قرابة 0.694). إنشاء ملف ملاحظات للمصادر.	دفتر يعمل، ونتيجة baseline قريبة من المرجع
12 إلى 14 نوفمبر	1. EDA والفرضيات	إعادة حساب «الملاحظات الثماني» من الجزء الثالث بنفسك، 4 إلى 6 رسوم، 3 فرضيات مكتوبة. بحث السوق قراءة فقط: نصف ساعة يومياً.	رسوم وفرضيات + قائمة مصادر أولية
15 إلى 19 نوفمبر	مسابقة الدورة (الأولوية)	أغلب وقتك للمسابقة. لـ Final Assignment: ساعة يومياً لقراءة مصادر السوق وتحديد مشكلتك (فقرة المشكلة). تجنب أي بناء نماذج جديدة لـ Final Assignment في هذه الأيام.	فقرة المشكلة + 5 مصادر على الأقل
20 نوفمبر	موعد المسابقة	4:00 فجراً بتوقيت العراق (حسب جدولك). بعدها استرح.	تسليم المسابقة
21 إلى 23 نوفمبر	2. الميزات والنماذج	معالجة، 5 ميزات مشتقة على الأقل بفرضيات، خط أساس، نموذجان أو أكثر، تحقق متقاطع، تسجيل كل تجربة.	جدول مقارنة النماذج
24 إلى 25 نوفمبر	3. التقييم والأثر	مصفوفة الالتباس، جدول الاستهداف (top-k)، أهمية الميزات، حساب الأثر مع سيناريوهات وافتراضات مكتوبة.	جدول الأثر + افتراضات

التاريخ	المرحلة	المهام	المخرج المطلوب
26 نوفمبر (الخميس)	4. الشرائح	مسودة كاملة، مراجعة الاتساق والاستشهادات. اطلب نقداً من Claude (الجزء الخامس). المحاضرة 2:00 إلى 3:30 ظهراً.	PDF مسودة بحد أقصى 15 شريحة
27 نوفمبر (الجمعة)	5. الفحص والتسليم	Restart and Run all، مطابقة أرقام الشرائح للدفتر، مطابقة المراجع، التسليم، التأكد من حالة التسليم.	**تسليم مكتمل في Omnicampus**
28 نوفمبر	احتياط	لا تعتمد عليه. الموعد 2:30 ظهراً بتوقيت العراق ولا يوجد تسليم متأخر.	فقط للطوارئ

إذا كانت امتحاناتك أو التزاماتك تضغط على أسبوع معين، فحرّك المراحل 2 و3 وليس 0 و1، لأن فهم البيانات المبكر هو ما يوفر عليك الوقت لاحقاً.

معيار «انتهت المرحلة»

المرحلة	تنتهي عندما تستطيع أن تقول
0. التجهيز	«أشغّل الدفتر من أوله إلى آخره، ونتيجتي قريبة من المرجع، وأفهم لماذا هناك فرق 10 نقاط بين دقة التدريب والاختبار.»
1. EDA	«أعدت حساب العتبتين بنفسي، وعندي فرضية أشرحها برسمين وبرقم، وأعرف ما سأختبره بعدها.»
المشكلة	«أقول مشكلة العميل في جملة، وأعرف من يتصرف بالنتيجة وماذا يفعل، وعندي مصادر تدعم أهمية المشكلة.»
2. الميزات والنماذج	«النموذج يتفوق على خط الأساس بوضوح (50.4%)، وأعرف لماذا اخترته، ولا أشك بالتسرب، ولدي سجل تجارب.»
3. التقييم والأثر	«أعرف كم أستهدف ولماذا، ورقم الأثر مبني على افتراضات مكتوبة وسيناريوهات وليس على 49.6% مباشرة.»
4. الشرائح	«شخص غير تقني يقرأ العناوين فقط ويفهم القصة كاملة.»
5. الفحص	«كل رقم في الشرائح يخرج من الدفتر الآن، وكل مصدر في الشرائح موجود في قائمة المراجع.»

إذا ضاق الوقت: ماذا تحمي وماذا تضحي به؟

لا تتنازل عنه (يهدد الاجتياز)	يمكن تقليصه أو حذفه
تسليم الشرائح والدفتر والمراجع قبل الموعد	الضبط الدقيق لمعاملات النموذج (لم يفد في بياناتك أصلاً)

لا تتنازل عنه (يهدد الاجتياز)	يمكن تقليصه أو حذفه
مقترح أعمال بتوصية واضحة وأثر كمي	مقارنة أكثر من نموذجين أو ثلاثة
اسم النموذج والمقياس والنتيجة نصاً على شريحة	ميزات مشتقة كثيرة (5 جيدة تكفي)
EDA حقيقي ورسوم متعددة	رسوم زخرفية ومخططات معقدة
مصادر موثقة وتحليل سوق	قسم الخطوات التالية المفصل
اتساق منطقي من البداية للنهاية	شريحة الاحتياط والملاحق

المخاطر العملية وكيف تتعامل معها

هذه أخطار متوقعة في مثل هذا المشروع، وما يقابلها من تصرف مقترح.

الخطر	ماذا تفعل
انقطاع جلسة Colab أو ضياع المتغيرات	احفظ الدفتر باستمرار، واجعل خلايا التحضير قابلة لإعادة التشغيل، واحفظ البيانات المعالجة في Drive إن لزم.
المسار لا يعمل	تأكد من ربط Drive وتغيير المسار في أمر cd كما يشرح الـ tutorial.
النموذج لا يتفوق على خط الأساس	راجع الدمج والمعالجة والتسرب قبل تغيير النموذج. وإن بقيت النتيجة ضعيفة فهذا طبيعي في بيانات صعبة (AUC نحو 0.70)، فاعرضها بصدق وركّز على الاستهداف.
لا تجد مصادر عراقية	وسّع إلى مصادر إقليمية أو عالمية مع ربطها بحالتك، واذكر بصراحة أن بيانات محلية لم تتوفر.
وقت قليل في أسبوع الامتحانات	اعتمد جدول «لا تتنازل عنه» أعلاه، وأنجز المراحل 0 إلى 1 مبكراً.
الشرائح مزدحمة	فكرة واحدة لكل شريحة، وانقل التفاصيل إلى الدفتر.
الاعتماد على نتيجة لم تفهمها (مثل عتبة 300 يوم)	اكتبها كملاحظة وفرضية، ووضّح أنك لم تتأكد من سببها.

الجزء الخامس: ماذا تفعل بنفسك وبماذا تستعين بـ Claude

القاعدة التي تحكم هذا الجزء مأخوذة من الـ FAQ الرسمي: يمكنك استعمال الذكاء الاصطناعي لمناقشة المقترحات وإنشاء المخططات وما شابه، **لكن نسخ المخرجات لا يُعتبر عملك**، ورابط المحادثة يجب أن يكون في المراجع. وما أقترحه هنا تفصيل عملي لهذه القاعدة، وهو يوافق ما اتفقنا عليه سابقاً: أشرح لك الفكرة والمفاهيم وأوجهك، وأنت تحل وتكتب.

> **المبدأ في جملة:** أنت تقرر وتحلل وتكتب وتفهم. Claude يشرح ويراجع وينتقد ويختبرك.

لماذا هذا التقسيم؟

- **التقييم:** المقترح يُقيَّم على تحليلك وتركيبك، والمصحح يرى أصالة تفكيرك.
- **الصدق:** استبيان الذكاء الاصطناعي في التسليم يسأل كم من المحتوى المساعَد تستطيع شرحه بكلماتك.
- **التعلم:** هدفك الحقيقي أن تصير قادراً على تكرار هذا النوع من العمل في وظيفة أو مقابلة، لا أن تحصل على ملف جاهز.
- **السيرة الذاتية:** أي سطر تكتبه فيها سيُسأل عنه في مقابلة.

جدول توزيع العمل

المهمة	أنت (بنفسك)	Claude (مساعد)
اختيار المشكلة والهدف	**تقرر** بعد EDA وبحث السوق وتكتب الجملة.	يعرض عليك بدائل ويسألك أسئلة تختبر اختيارك.
بحث السوق	**تبحث وتقرأ وتوثق** المصادر.	يقترح أنواع المصادر وكلمات البحث، ويشرح مصطلحات صعبة. لا تعتمد عليه كمصدر أرقام.
EDA	**تكتب الكود وتقرأ الرسوم وتصيغ الفرضيات.**	يشرح دالة أو مفهوماً، ويراجع كودك عند الأخطاء، ويسألك «ماذا يعني هذا الرسم؟».
التسرب والتنظيف	تقرر ما يُحذف وما يبقى.	يشرح أنماط التسرب الشائعة ويراجع منطقك.
هندسة الميزات	**تقترح الميزة وتكتب سبباً متوقعاً.**	يناقش جدواها، وقد يقترح أفكاراً إضافية تقيّمها أنت.
الموديل والتقييم	**تبني وتقارن وتفسر.**	يشرح المقاييس والفرق بينها، ويفحص كودك، ويدلك على أخطاء منهجية.
حساب الأثر	**تحدد الافتراضات والأرقام وتحسب.**	يتحقق من حسابك ومن اتساق الوحدات، ويقترح سيناريوهات حساسية.

المهمة	أنت (بنفسك)	Claude (مساعد)
الشرائح	**تكتب العناوين والمحتوى وتصمم.**	ينتقد وضوح الرسالة ويراجع اللغة والاتساق المنطقي.
الدفتر النهائي	تنظفه وتشغله كاملاً.	يراجع الأخطاء الظاهرة والتنظيم.
الاستعداد للمقابلة	تجيب بصوتك.	يسألك أسئلة محاور ويعلّق على إجاباتك.

أمثلة على طلبات جيدة

الطلب الجيد يحتوي **ما فعلته أنت**، ثم يسأل عن **مراجعة أو شرح**، لا عن «الحل». وهذه صيغ تصلح قوالب (أبدل ما بين الأقواس).

الحاجة	صيغة الطلب
فهم مفهوم	اشرح لي [المفهوم] بمثال بسيط من الاتصالات، ثم اسألني سؤالين لأتأكد أنني فهمت.
مراجعة كود	هذا كودي لـ [الخطوة]. لا تعطني نسخة جديدة. قل لي أين الخطأ المنهجي المحتمل ولماذا، وأعطني تلميحاً لأصلحه بنفسي.
مراجعة فرضية	هذه فرضيتي: [..] وهذا الرسم يدعمها: [..]. ما البدائل التي قد تفسر النتيجة نفسها؟ وكيف أختبرها؟
التسرب	هذه الأعمدة التي أستعملها: [..]. أيها قد يسرّب الهدف؟ علّل ولا تحذف شيئاً بدلاً مني.
اختيار المقياس	هدفي [..] وتوزيع الفئات [..]. ما الفرق بين Precision وRecall هنا من ناحية الكلفة؟ ما الأقرب لحالتي ولماذا؟
حساب الأثر	هذه معادلتي وهذه الأرقام والافتراضات: [..]. افحص المنطق والوحدات، وقل لي أي افتراض أضعف.
نقد الشرائح	هذه شرائحي: [..]. اقرأ العناوين فقط وأخبرني ما القصة التي فهمتها. أين ينقطع الاتساق؟
التبسيط	هذه الفقرة: [..]. هل يفهمها مدير بلا خلفية تقنية؟ ما الجمل الغامضة؟ (أنا أعيد كتابتها.)
اختبار	اسألني 10 أسئلة كما يسأل محاور عن هذا المشروع، واحداً واحداً، وعلّق على إجابتي بعد كل سؤال.

أمور لا تفعلها

هذه أنماط استعمال تضرك أكثر مما تنفعك، لأسباب مذكورة بجانب كل منها.

لا تفعل	لماذا
«اكتب لي النوتبوك كاملاً» أو «ابنِ الشرائح كلها»	ستخسر الأصالة، ولن تستطيع الدفاع عن شيء، ونسخ المخرجات لا يُعتبر عملك.
«اختر لي المشكلة والهدف»	هذه أهم قرار، وأي شخص يطلب نفس الطلب سيحصل على نفس الجواب.
استعمال رقم من Claude كمصدر في السوق	الأرقام يجب أن تأتي من مصدر منشور تقرأه أنت وتوثقه.
لصق كود لا تفهمه	سيسألك Q4 في الاستبيان، وسيسألك المحاور لاحقاً.
وضع محتوى منسوخ بدون استشهاد	قد يُعد انتحالاً حتى لو أعيدت صياغته جزئياً.
مشاركة بيانات حساسة أو سرية في المحادثة	الاستبيان نفسه يطلب ألا تلصق معلومات شخصية أو سرية.
الثقة العمياء بأي رقم أو فكرة من أي ذكاء اصطناعي	يخطئ أحياناً. تحقق بنفسك من الحسابات والمفاهيم.

توثيق استعمال الذكاء الاصطناعي

- **ضع رابط محادثة (أو محادثات) Claude في حقل المراجع** عند التسليم. هذا شرط صريح في الـ README والـ FAQ.
- أبقِ استعمالك في محادثات مرتبة بحسب المراحل (مثلاً محادثة للـ EDA ومحادثة للأثر)، حتى يسهل عليك عرضها وتذكر ما فعلته.
- تحقق من أن الرابط يفتح ويعرض المحادثة كاملة قبل التسليم. لا أستطيع أن أؤكد لك خطوات إنشاء الرابط الحالية في واجهة Claude، فاستعمل خيار المشاركة المتاح عندك، وإن لم تجده فاسأل المنظمين في Slack عن الطريقة المقبولة.
- المحتوى الذي كتبته أنت ولم تستعمل فيه الذكاء الاصطناعي لا يحتاج توثيقاً بهذا الشكل، لكن ما استعرته من أي مصدر يحتاج استشهاداً.

شرح حقول استبيان الذكاء الاصطناعي في صفحة التسليم

الاستبيان مكتوب بوضوح أنه **لا يؤثر على الدرجة**، وغرضه أن يفهم المنظمون كيف يستعمل الطلاب هذه الأدوات. أجب بحسب ما حدث فعلاً. هذه الحقول وكيف تُملأ:

السؤال	ما يسأل عنه	كيف تجيب
Q1	هل استعملت ذكاءً اصطناعياً توليدياً (برمجة أو كتابة أو تحرير)؟	اكتب رقماً واحداً: 1 إذا نعم، 2 إذا لا. إذا اخترت 2 فاكتب N/A للأسئلة من 2 إلى 4.
Q2	أي أجزاء استعملت فيها الذكاء الاصطناعي؟	أرقام مفصولة بفواصل مثل 1, 3, 6: (1) بحث السوق وأفكار، (2) EDA ورسوم، (3) المعالجة وهندسة الميزات، (4) بناء الموديل وتفسير النتائج، (5) ترجمة الـ ML إلى مقترح بأثر كمي، (6) الشرائح والصياغة والترجمة، (7) المراجع والاستشهادات، (8) غرض آخر.

السؤال	ما يسأل عنه	كيف تجيب
Q3	أي أدوات؟	أرقام مفصولة بفواصل: (1) ChatGPT، (2) Claude، (3) Gemini، (4) GitHub Copilot، (5) أداة أخرى، (6) لا أتذكر أو أفضل عدم الإجابة. إذا اخترت 6 فاكتب 6 فقط.
Q4	كم من المحتوى المساعَد تستطيع شرحه بكلماتك؟	رقم واحد: (1) كله 100%، (2) أغلبه 75 إلى 99%، (3) أكثر من النصف 51 إلى 74%، (4) أقل من النصف 25 إلى 50%، (5) قليل، (6) غير متأكد أو أفضل عدم الإجابة.

كل إجابة محدودة بين 1 و500 حرف، والمجموع 2000 حرف. أجب بالأرقام كما يطلب النموذج. الهدف الذي نعمل عليه معاً أن تكون إجابتك عن Q4 صادقة وقوية: أن تستطيع فعلاً شرح كل شيء في تسليمك.

اختبار الفهم قبل التسليم

قبل ضغط Submit جرّب هذا الاختبار، ويمكنك أن تطلب من Claude أن يحاورك فيه:

- اشرح كل شريحة بصوت عالٍ دون النظر لأي ملاحظات، في دقيقة لكل شريحة.
- اشرح كل خلية في الدفتر: ماذا تفعل ولماذا هي هنا.
- اشرح لماذا اخترت الموديل ولماذا لم تختر غيره.
- اشرح كل رقم في الأثر المالي: من أين جاء، وماذا يحدث لو تغير؟
- اذكر أضعف نقطة في مقترحك قبل أن يسألك أحد عنها.

إذا لم تستطع الإجابة عن شيء، فهذا موضع تعلم، وليس سبباً للقلق. اطلب شرحه، ثم أعد صياغته بنفسك.

الجزء السادس: القاموس والمراجعة وحدود المعلومات

قاموس المصطلحات

المصطلح	المعنى المبسط
Churn	مغادرة العميل للشركة. في هذه البيانات: مغادرة خلال 31 إلى 60 يوماً بعد تاريخ الملاحظة.
Voluntary / Involuntary churn	مغادرة بقرار العميل، أو مغادرة غير طوعية (عدم دفع مثلاً).
ARPU	متوسط الإيراد لكل مستخدم (Average Revenue Per User).
PoC	إثبات مفهوم: تجربة أولية قبل التنفيذ الكامل.
EDA	التحليل الاستكشافي: فهم البيانات بالرسوم والأرقام قبل بناء الموديل.
Target (الهدف)	ما نحاول توقعه (مثل churn).
Feature (ميزة)	عمود يستعمله الموديل كمدخل.
Feature engineering	إنشاء ميزات جديدة من الأعمدة الموجودة (نسب، فروق، تجميعات).
Data leakage (تسرب)	دخول معلومة للموديل لا تكون متاحة وقت التنبؤ، أو مشتقة من الهدف، فتبدو النتيجة أحسن مما هي.
Train / Test split	تقسيم البيانات: جزء للتدريب وجزء لم يره الموديل لتقييمه.
Stratify	تقسيم يحافظ على نسب الفئات في الجزأين.
random_state	رقم يثبّت العشوائية لتتكرر النتائج.
Baseline (خط الأساس)	مقارنة بسيطة يجب أن يتفوق عليها الموديل (مثل توقع الفئة الأكبر دائماً).
Overfitting	حفظ الموديل للتدريب وضعف أدائه على بيانات جديدة.
Cross-validation	تكرار التدريب والتقييم على أجزاء مختلفة للحصول على نتيجة أثبت.
Accuracy	نسبة التوقعات الصحيحة من الكل.
Confusion matrix	جدول بأربع خانات يبين أنواع الصواب والخطأ.
Precision	من بين من توقعنا مغادرتهم، كم نسبة من غادر فعلاً.
Recall	من بين من غادر فعلاً، كم نسبة من التقطنا.
F1	مقياس يجمع Precision وRecall (وسط توافقي).
AUC	قدرة الموديل على ترتيب المغادرين فوق الباقين، بغض النظر عن حد قطع.

المصطلح	المعنى المبسط
predict_proba	دالة تعطي احتمال كل فئة لكل عميل (مفيدة لترتيب العملاء).
Top-k% targeting	استهداف أعلى k% من العملاء بحسب درجة الموديل.
Lift	كم مرة تكون نسبة المغادرين في الشريحة المستهدفة أعلى من النسبة العامة.
Feature importance (gain)	مقدار تحسين الموديل عند استعمال الميزة (مقياس في XGBoost).
LabelEncoder	تحويل نصوص الفئات إلى أرقام صحيحة، مع عيب فرض ترتيب مصطنع.
Lever (رافعة)	عامل يمكن للشركة أن تغيره فعلاً لتحسين النتيجة.
Sensitivity analysis	تجربة كيف تتغير النتيجة عند تغيير الافتراضات.
Reproducibility	قدرة شخص آخر على إعادة تشغيل عملك والحصول على النتائج نفسها.

أسئلة مراجعة

اقرأ السؤال وأجب بصوتك قبل أن تنظر إلى الجواب. الأسئلة من 21 إلى 27 مبنية على أرقام بياناتك.

السؤال	الجواب المختصر
1. ما الفرق بين تقرير تقني ومقترح أعمال؟	التقرير يعرض نتائج الموديل. المقترح يقدم قراراً وأثراً مقدَّراً مبنياً على الدليل.
2. ماذا يجب أن يظهر نصاً على شريحة الموديل؟	اسم الموديل والمقياس والنتيجة. الصور وحدها لا تكفي.
3. كم شريحة مسموحة؟	حتى 15 شريحة بما فيها العنوان والفهرس والمراجع. الزائد قد يُهمَل.
4. ما الحد التقريبي للاقتباس الحرفي؟	أقل من 40% من المادة النهائية.
5. هل التسليم المتأخر مقبول؟	لا. وإعادة التسليم مقبولة قبل الموعد فقط، ويجب إرفاق كل الملفات.
6. ماذا تفعل إن استعملت الذكاء الاصطناعي؟	تضع رابط المحادثة في المراجع، وتجيب عن الاستبيان بصدق.
7. ما شرط الـ Honors؟	حضور 7 أو أكثر، و14 نقطة واجبات أو أكثر، وFinal Assignment ضمن أعلى 10%، وCompetition ضمن أعلى 20% (حسب شريحة Recap).
8. لماذا تكون الدقة مفيدة هنا؟	لأن الفئات شبه متوازنة (حسب الـ tutorial). لو كانت المغادرة 5% لضللت الدقة.
9. ما التسرب (leakage)؟	ميزة تحمل معلومة غير متاحة وقت التنبؤ أو مشتقة من الهدف، فتضخم الأداء.
10. لماذا stratify؟	للحفاظ على نسب الفئات في التدريب والاختبار.

السؤال	الجواب المختصر
11. ما عيب LabelEncoder؟	يفرض ترتيباً مصطنعاً، ويحوّل NaN إلى فئة نصية اسمها nan.
12. متى يكون Precision أهم من Recall؟	عندما يكون الإنذار الكاذب مكلفاً، كعرض مكلف يُقدَّم لمن لن يغادر.
13. ما معنى الأهمية بحسب gain؟	مقدار ما تحسّنه الميزة من أداء الموديل عند استعمالها في الأشجار.
14. لماذا لا تكفي الأهمية وحدها لبناء توصية؟	لأنها لا تعني السببية، ولا تقول إن الشركة تستطيع تغيير الميزة. نحتاج «أهمية مع قابلية تدخل».
15. اكتب معادلة الأثر الصافي.	المستهدفون × نسبة المغادرين بينهم × نجاح التدخل × قيمة العميل − المستهدفون × كلفة التدخل.
16. في المثال الوهمي (10,000 مستهدف، 60%، 20%، 300، 15) كم الصافي؟	210,000 (الإيراد 360,000 ناقص الكلفة 150,000).
17. لماذا ذكرنا ملاحظة 50% churn؟	لأن نسبة المغادرة الواقعية أقل، وتطبيق نسب العينة مباشرة على السوق قد يبالغ في الأثر.
18. ماذا تفعل قبل التسليم بالدفتر؟	Restart session وRun all، وتطابق الأرقام مع الشرائح.
19. هل المشروع يصلح للسيرة الذاتية؟	نعم كمشروع دراسي، مع صدق في الوصف والأرقام، ومن دون ادعاء تنفيذ حقيقي.
20. ما دور Claude في العمل؟	شرح ومراجعة ونقد واختبار، وليس كتابة الحل أو اختيار المشكلة.
21. ما نسبة المغادرة في بياناتك وماذا تعني للحسابات؟	49.56%. وهي غير واقعية، فيجب تعديل الحسابات المالية أو توضيح الافتراض.
22. كم تحقق نتيجة نموذج الـ tutorial على بياناتك؟	Accuracy قرابة 63.6% وAUC قرابة 0.694 على الاختبار، مقابل 50.4% لخط الأساس.
23. ما العتبتان البارزتان في البيانات؟	عمر الجهاز نحو 300 يوم، ومدة الاشتراك بين 10 و11 شهراً.
24. ما مجموعة العملاء الأعلى مغادرة؟	من mou_Mean عندهم صفر (1,615 عميلاً، مغادرة 79.8%).
25. هل change_mou نسبة مئوية؟	على الأرجح لا (22.6% من قيمه أقل من −100). يبدو فرقاً مطلقاً.
26. لماذا الإيراد وحده لا يكفي لتحديد القيمة؟	لأن المغادرين والباقين متقاربون جداً في الإيراد (58.2 مقابل 59.2).
27. ماذا يتحسن أكثر في بياناتك: الميزات أم الضبط؟	الميزات المشتقة (نحو +0.005 AUC)، أما الضبط وحده فلم يضف شيئاً.

قائمة الفحص قبل التسليم

البند	ماذا تتأكد منه
المحتوى	توصية واضحة، أثر كمي بافتراضات، رسوم متعددة، عناوين تقول الفكرة.
الموديل	الاسم والمقياس والنتيجة مكتوبة نصاً، ومبررة، ومقارنة بخط أساس.
السوق	أرقام موثقة بمصادر قابلة للاستشهاد، مرتبطة بحالة Company A.
الاتساق	كل شريحة تقود إلى التالية، والأرقام ثابتة بين الشرائح.
الاستشهاد	إشارة على كل شريحة فيها مصدر، وقائمة المراجع مطابقة.
الذكاء الاصطناعي	رابط المحادثة في المراجع، والاستبيان معبأ بصدق.
الملفات	أسماء بحسب حسابك في Omnicampus، الشرائح PDF بحد أقصى 15 وبحجم 10MB أو أقل، الدفتر يعمل من أوله لآخره.
التسليم	كل الملفات والمراجع مرفقة، وضغطت Submit، وتأكدت من الحالة بعد ذلك.
الخصوصية	لا بيانات شخصية أو مفاتيح داخل الدفتر، ولا نشر علني للبيانات.
التوقيت	التسليم قبل الموعد بيوم، الموعد 28 نوفمبر 2:30 ظهراً بتوقيت العراق.

حدود المعلومات

هذه قائمة صريحة بما لا أستطيع الجزم به، حتى لا تبني عليها قراراً بدون تحقق.

- **ما تحقق من أرقام البيانات:** حلّلت Client_1.csv وRecord.csv بنفسي، لكن بنموذج واحد (XGBoost) وبعدد محدود من التجارب. الأرقام (العتبات، جداول الاستهداف، نتائج التجارب) صحيحة لهذا التحليل، وقد تختلف أرقامك قليلاً بإصدار مكتبة مختلف. **لم أجرّب كل فكرة ممكنة**، فهي ليست سقف ما يمكن تحقيقه.
- **تفسير الاكتشافات:** لا أعرف لماذا توجد عتبة عند 300 يوم وعند 10 أشهر. هل هي سلوك حقيقي أو أثر لطريقة تكوين العينة؟ أي تفسير أقدمه فرضية وليس حقيقة.
- **الاستنتاجات عن أعمدة بلا وصف:** عن iwylis_vce_Mean (مكالمات واردة لاسلكية) وعن change_mou (فرق مطلق) هي استنتاجات من الأنماط، وليست تأكيداً من الشركة.
- **نسبة churn 49.6%** حقيقية في الملفات (محسوبة)، لكن سبب هذا التوازن غير معروف.
- **حدود Honors (أعلى 10% و20%) وعتبات الحضور والواجبات** مأخوذة من شريحة Recap في شرائح الـ tutorial. لم أجد في الملفات طريقة احتساب «أعلى 10%» ولا معيار اختيار Outstanding (الـ README يقول إن التفاصيل ستُنشر في Slack).
- **الموعد** مأخوذ من الـ README ومن شريحة Submission Deadline (28 نوفمبر 11:30 UTC). بعض صور Omnicampus في الشرائح من دفعة سابقة، فتأكد من الموعد في حسابك.
- **موعد مسابقة الدورة (20 نوفمبر 1:00 UTC)** ذكرته اعتماداً على معلومة سبق أن ذكرتها في المحادثة، ولم أتحقق منها من مصدر رسمي هنا.
- **حقوق نشر البيانات والشرائح** غير مذكورة في الملفات. لذلك نصحتك بعدم النشر العلني قبل سؤال المنظمين.

- **شرح المفاهيم** (المقاييس، التسرب، التحقق المتقاطع، الدوال المقترحة) من معرفتي العامة بتعلم الآلة وليس من مصادر استشهاد جديدة. هي معلومات قياسية، لكن راجع المراجع الرسمية لمكتبات scikit-learn وXGBoost عند الحاجة.
- **السوق العراقي والمصادر:** لم أبحث عن أرقام السوق ولم أقدم أي رقم عنه. ذكرت أنواع مصادر وأسماء جهات للبحث فقط، وعليك التحقق من وجودها وحداثتها.
- **واجهة Omnicampus وكيفية مشاركة رابط محادثة Claude:** لم أتحقق من الواجهة الحالية للمنصتين، فاتبع ما تراه فيهما أو اسأل المنظمين.
- **الأثر المالي** في المثال بأرقام وهمية لغرض الشرح، وليس نتيجة لأي تحليل.
- **الخطة الزمنية والمقترحات في الجزأين الرابع والخامس** هي اقتراحات مني، وليست متطلبات رسمية.

المصادر المستعملة

هذه هي الملفات التي بُني عليها الدليل فعلاً، وليس غيرها.

المصدر	ما أخذته منه
Final Assignment README (GCI World 2026 September)	السيناريو، المتطلبات، الاستشهاد، التسليم، التقييم، الـ FAQ، مسار العمل المقترح، نصائح الشرائح.
شرائح Final Assignment Tutorial	مستويات Completed وHonors وOutstanding، مسار العمل، الـ FAQ، موعد التسليم وفتح التسليم.
ENG Company A Dataset Overview	وصف الملفين والأعمدة وغموض بعضها.
Client_1.csv وRecord.csv (تحليلي أنا)	كل أرقام الجزء الثاني: الهيكل والجودة والعتبات والنماذج.
tutorial.ipynb	خطوات الدفتر، الأسئلة التوجيهية، تفاصيل الموديل وطريقة التقييم وتعليقات حول الحدود.
صفحة الاستبيان التي ألصقتها من Omnicampus	أسئلة استبيان الذكاء الاصطناعي وخياراتها.

بالتوفيق يا إسلام. أنت الآن تعرف ما المطلوب، ولماذا، وكيف تقسم الوقت. ابدأ بالخطوة 0 اليوم، وإذا علقت في أي خطوة أرسل لي ما فعلته (الكود أو الرسم أو الفكرة) وسنراجعه معاً، وأنت من يقرر ويكتب. وأستطيع تعميق أي جزء تريده.